

부산대학교 정보컴퓨터공학부 졸업과제 착수보고서

LLM 서사 생성 시스템의 환각 방지 아키텍처 설계 및 구현

- 결정론적 연산-서술 분리와 다계층 검증을 중심으로 -

과제명	LLM 서사 생성 시스템의 환각 방지 아키텍처 설계 및 구현
팀명	Hallucination
졸업과제번호	2
분과	A
지도교수	박진선 교수님
제출일	2026년 5월 15일

학번	이름	역할	메일주소
202155557	박찬오	코어 아키텍처, 결정론적 게임 시스템, 상태 검증 구조	opark001@pusan.ac.kr
202155524	김동현	모바일 클라이언트 통신, 실시간 플레이 런타임	sua3801@pusan.ac.kr
202355637	신승훈	AI 엔지니어링, 생성 모델 일관성, 검증 자동화	uitopia04@pusan.ac.kr

Contents

1	프로젝트 개요	2
1.1	과제 정의	2
1.2	대상 서비스: 더 넥서스	2
1.3	과제 목표	2
1.4	착수 시점 구현 현황	3
2	개발 배경 및 필요성	3
2.1	LLM 기반 서사 생성의 장점	3
2.2	대상 문제: 서사 환각과 상태 오염	3
2.3	출업과제로서의 설계 가치	4
3	대상 문제 및 요구조건 분석	4
3.1	문제 정의	4
3.2	기능 요구사항	4
3.3	비기능 요구사항	5
3.4	입출력 명세	6
4	시스템 설계	6
4.1	전체 아키텍처	6
4.2	결정론적 연산-서술 분리	6
4.3	다계층 검증 구조	7
4.4	YAML SSoT와 DataBridge	7
4.5	메모리 시스템	8
4.6	하이퍼그래프 관계 엔진	8
4.7	장면 이미지 생성 보조 계층	8
5	모바일 애플리케이션 설계	8
5.1	모바일 앱의 역할	8
5.2	주요 화면	9
5.3	사용자 흐름	9
6	현실적 제약사항 분석 및 대책	9
6.1	LLM 환각	9
6.2	응답 지연과 API 비용	10
6.3	텍스트-이미지 일관성	10
6.4	데이터 일관성	10
6.5	모바일 연동 범위	10
6.6	시연 환경	10
7	추진 체계 및 일정	10
7.1	개발 단계	10
7.2	역할 분담	11
8	검증 및 평가 계획	11
8.1	정량 평가	11
8.2	정성 평가	12
8.3	주요 테스트 계획	12
9	기대 효과 및 향후 발전 방향	13
9.1	기대 효과	13
9.2	향후 발전 방향	13
10	결론	13

1. 프로젝트 개요

1.1. 과제 정의

본 과제는 LLM이 실시간으로 서사를 생성하는 인터랙티브 텍스트 RPG 시스템에서, 생성형 AI의 환각이 게임 상태를 오염시키지 않도록 하는 다계층 검증 아키텍처를 설계하고 구현하는 것을 목표로 한다. 결과물은 사용자가 모바일 환경에서 선택지를 고르고, 시스템이 전투와 성장 같은 결정론적 연산을 확정하며, LLM이 그 결과를 바탕으로 서사를 생성하는 AI 서사 RPG 애플리케이션이다. 이 애플리케이션은 단순 채팅형 대모가 아니라, 가상 MMORPG 세계의 플레이 루프, 장기 기억, 관계 그래프, 데이터 검증, 실시간 스트리밍, 장면 이미지 생성을 함께 다루는 통합형 생성 AI 게임 시스템이다.

본 과제의 핵심은 “AI로 이야기를 생성하는 게임” 자체가 아니라, LLM이 자유롭게 문장을 생성하더라도 HP, MP, 아이템, 장비, 레벨, 전투 결과, 세계관 규칙 같은 시스템 진실은 훼손되지 않도록 설계하는 데 있다. 따라서 본 프로젝트는 게임 콘텐츠 프로젝트인 동시에 LLM 기반 응용 시스템의 신뢰성 보장 문제를 다루는 소프트웨어 설계 과제이다.

1.2. 대상 서비스: 더 넥서스

서비스 배경은 100개 층의 가상 세계를 공략하는 1인용 텍스트 RPG이다. 플레이어는 혼자 게임을 진행하지만, 세계 내부에는 AI가 시뮬레이션하는 다른 플레이어들이 존재한다. 이 세계에는 NPC가 없으며, 모든 만남은 다른 플레이어와의 상호작용으로 표현된다. 상점, 의뢰소, 거래 기능은 사람이 아닌 무인 키오스크 또는 시스템 게시판으로 처리된다.

세계관의 기본 규칙은 다음과 같다.

- 모든 플레이어는 0층에서 시작하며, 100층 클리어를 장기 목표로 삼는다.
- HP가 0이 되면 캐릭터는 영구 사망하며, 부활이나 리스폰은 존재하지 않는다.
- 층간 이동은 각 층 중앙의 넥서스 노드를 통한 전송으로만 가능하다.
- 전투 수치와 보상은 시스템이 확정하며, LLM은 그 결과를 서술로 표현한다.
- 텍스트 채팅은 없고, 모든 소통은 같은 공간에 있는 플레이어 간 직접 대화로 처리된다.

이러한 설정은 단순한 분위기 요소가 아니라 시스템 설계 조건이다. 예를 들어 LLM이 임의로 NPC 상인을 등장시키거나, 보유하지 않은 장비를 획득했다고 서술하거나, HP가 0이 아닌데 영구 부상을 만들면 세계관과 게임 상태가 동시에 깨진다. 본 과제는 이 문제를 구조적으로 차단하는 것을 핵심 목표로 삼는다.

1.3. 과제 목표

본 과제의 최종 목표는 다음과 같다.

1. 100층 가상 세계 “더 넥서스”를 배경으로, 캐릭터 생성, 프로필로그, 튜토리얼 장비 선택, 장면 선택지, 전투, 성장, 저장과 재개가 이어지는 실제 플레이 루프를 구현한다.
2. 결정론적 게임 엔진과 LLM 서사 엔진을 분리하여, HP, MP, 아이템, 장비, 경험치, 전투 결과 같은 상태 변경 권한을 시스템에만 부여한다.
3. 장면 서술 생성과 상태 변화 추출을 분리한 2단계 LLM 구조를 사용하여, 자연어 서술의 자유도와 시스템 데이터의 안정성을 동시에 확보한다.
4. LLM 출력에 대해 스키마 검증, 상태 검증, 세계관 검증, 관계 검증, 메모리 검증, rejection feedback을 수행하는 다계층 검증 파이프라인을 구현한다.
5. YAML 기반 단일 데이터 원천과 DataBridge 조회 계층을 통해 전투, 직업, 장비, 몬스터, 층, 세계관 데이터의 참조 일관성을 유지한다.
6. 4계층 메모리와 하이퍼그래프 관계 엔진을 결합하여, 장기 플레이에서 과거 사건과 다른 플레이어 관계가 일관되게 재사용되도록 한다.
7. REST API, SSE 스트리밍, Streamlit 검증 클라이언트, Flutter/HX 기반 모바일 화면을 연동하여 시연 가능한 AI 서사 RPG 사용자 경험을 완성한다.

8. 모바일 클라이언트와 서버 사이의 메시지 순서, 맥등성, 세션 복구, 오류 피드백을 정의하여 장시간 플레이 중 상태 동기화가 어긋나지 않도록 한다.
9. 테스트, 데이터 검증 스크립트, 전투 시뮬레이터, playbot 로그, guardrail rejection 분석을 통해 단순 프롬프트 방식 대비 구조적 검증 방식의 효과를 정량적으로 평가한다.

1.4. 착수 시점 구현 현황

본 과제는 현재 구축된 백엔드, 데이터 기반, Streamlit 기반 검증용 클라이언트, Flutter/HX 화면 설계 산출물을 바탕으로, 졸업과제 기간 동안 모바일 최적화 클라이언트와 시연 가능한 통합 시스템을 완성하는 것을 범위로 한다. 착수 시점 기준 구현 현황은 표 1과 같다.

구현 현황과 정량 지표는 착수보고서 작성 시점의 소스 코드, 데이터 파일, 검증 스크립트, 실행 가능한 모듈 구조를 기준으로 정리하였다.

Table 1: 착수 시점 구현 현황

항목	현황
서버 Python 소스	184개 파일, 48,657줄
YAML 데이터	615개 파일
테스트 파일	125개 파일
설계 및 기술 문서	121개 파일
FastAPI 라우트 정의	34개
Streamlit 검증 클라이언트	36개 파일, 4,840줄
Flutter/HX 디자인 시스템	18개 Dart 파일, 3,009줄
StateGuardrail	2,474줄
DataBridge	1,544줄
메모리 시스템	11개 파일, 1,237줄
하이퍼그래프 엔진	7개 파일, 841줄
전투 서브시스템	24개 파일, 10,211줄
게임 루프 서브시스템	30개 파일, 10,870줄
장면 이미지 생성 계층	6개 파일, 1,441줄

표의 수치는 착수보고서 작성 시점의 프로젝트 구현체를 직접 측정한 값이다.

2. 개발 배경 및 필요성

2.1. LLM 기반 서사 생성의 장점

전통적인 RPG는 사전에 작성된 대사, 퀘스트, 이벤트 스크립트를 조합해 플레이어 경험을 만든다. 이 방식은 안정적이지만, 반복 플레이에서 예측 가능성이 높고 콘텐츠 생산 비용이 크다. LLM 기반 서사 생성은 플레이어의 선택, 캐릭터 상태, 이전 사건, 주변 인물 관계를 입력으로 받아 매 순간 새로운 문장을 생성할 수 있으므로, 고정 스크립트보다 더 유연한 인터랙티브 경험을 제공한다.

특히 텍스트 RPG에서는 그래픽보다 서술 품질과 상태 일관성이 중요하다. LLM은 문장 생성 능력이 뛰어나지만, 동시에 존재하지 않는 사건을 만들어내거나, 시스템이 확정하지 않은 보상을 부여하거나, 이전 장면과 모순되는 설정을 제시할 수 있다. 이 문제를 방지하면 플레이어는 게임 규칙을 신뢰할 수 없고, 장기 플레이에서 데이터가 급격히 오염된다.

2.2. 대상 문제: 서사 환각과 상태 오염

본 과제에서 다루는 환각은 단순한 사실 오류가 아니라 게임 상태를 파괴하는 출력이다. 대표적인 문제는 다음과 같다.

- **수치 환각:** LLM이 전투 결과와 무관하게 HP, MP, 경험치, 보상을 변경한다.
- **아이템 환각:** 시스템에 존재하지 않는 장비를 획득하거나, 인벤토리에 없는 아이템을 사용했다고 서술한다.

- **세계관 환각:** NPC가 없는 세계에서 NPC 상인, NPC 안내자, 귀환 주문, 로그아웃 버튼 등을 등장시킨다.
- **관계 환각:** 이전에 만난 플레이어의 이름, 직업, 레벨, 태도, 관계를 임의로 바꾼다.
- **장기 기억 오염:** 잘못된 서술이 메모리에 저장되어 이후 프롬프트에 반복 주입된다.

이 문제는 프롬프트만으로 해결하기 어렵다. 프롬프트는 LLM의 행동을 유도할 수 있지만, 출력이 항상 규칙을 지킨다고 보장하지 않는다. 따라서 본 과제는 프롬프트 설계와 별도로 시스템 수준의 검증 계층을 둔다.

2.3. 졸업과제로서의 설계 가치

본 과제는 교과 지식을 응용해 실제 시스템을 구현하는 설계과제의 요건을 충족한다. 주요 설계 요소는 다음과 같다.

- FastAPI 기반 서버와 모바일 클라이언트의 네트워크 연동
- 게임 상태를 결정론적으로 계산하는 백엔드 도메인 모델
- 장면 서술 생성과 상태 변화 추출을 분리한 2단계 LLM structured output 구조
- StateGuardrail과 검증 파이프라인을 결합한 신뢰성 아키텍처
- YAML 데이터와 DataBridge를 이용한 단일 데이터 원천 관리
- 4계층 메모리와 하이퍼그래프를 이용한 장기 맥락 관리
- PostgreSQL(Supabase)/SQLAlchemy 기반 세션, 메모리, 그래프 영속화
- SSE 스트리밍 기반 실시간 서사 표시
- 장면 서술과 이미지 프롬프트를 연결하는 멀티모달 보조 계층

3. 대상 문제 및 요구조건 분석

3.1. 문제 정의

본 과제의 문제 정의는 다음과 같다.

LLM이 생성한 서사가 플레이어 경험을 풍부하게 만들도록 허용하되, 게임 상태와 세계관 규칙은 시스템이 확정한 진실에서 벗어나지 않도록 보장하는 AI 서사 생성 시스템을 설계하고 구현한다.

이를 위해 시스템은 사용자 입력, 캐릭터 상태, 게임 데이터, 세계관 규칙, 이전 사건 기억을 결합해 프롬프트를 구성하고, LLM 출력이 시스템 계약을 위반하는지 검증한 뒤에만 상태를 반영해야 한다.

3.2. 기능 요구사항

Table 2: 기능 요구사항

번호	요구사항	설명
FR-1	캐릭터 생성	이름, 성별, 나이, 진입 Day, 외형/음색 프리셋, 가치관을 입력해 노비스 캐릭터를 생성한다. 시작 무기 선택은 캐릭터 생성이 아니라 프롤로그 장면의 튜토리얼 선택지로 처리한다.
FR-2	선택지 기반 진행	매 장면마다 플레이어에게 선택지를 제공하고, 선택 결과를 다음 장면 생성에 반영한다.
FR-3	전투 자동 판정	전투 발생 여부, 피해량, 보상, 드랍은 시스템이 계산하고 LLM은 결과를 서술한다.

번호	요구사항	설명
FR-4	LLM 서사 생성	현재 상태, 세계관, 메모리, 시스템 관정 결과를 입력으로 장면 서술을 생성한다.
FR-5	다계층 검증	LLM 출력의 스키마, 수치, 아이템, 장비, 플레이어 관계, 세계관 위반 여부를 검증한다.
FR-6	메모리 관리	현재 장면, 에피소드, 장기 정보가 구분된 메모리 계층을 통해 장기 플레이 맥락을 유지한다.
FR-7	관계 그래프 관리	다른 플레이어와의 만남, 적대, 동맹, 공유 사건을 하이퍼그래프로 기록한다.
FR-8	클라이언트 플레이	현재 Streamlit 클라이언트에서 REST/SSE 플레이 루프를 검증하고, 졸업과제 산출물에서는 모바일 앱으로 장면 서술, 선택지, 캐릭터 상태, 인벤토리 등 핵심 UI를 제공한다.
FR-9	저장 및 재개	플레이어 세션과 캐릭터 상태를 저장하고 이어서 플레이할 수 있도록 한다.
FR-10	검증 로그	검증 실패, rejection, 시스템 진실 강제, LLM 사용량을 분석 가능한 로그로 기록한다.
FR-11	2단계 생성 구조	1단계에서는 장면 서술을 생성하고, 2단계에서는 상태 변화만 추출하여 서술 자유 영역과 상태 변경 영역을 분리한다.
FR-12	장면 이미지 보조	LLM 서술에서 이미지 생성용 프롬프트를 분리하고, 장면 단위 이미지 생성/조회 경로를 제공한다.

3.3. 비기능 요구사항

Table 3: 비기능 요구사항

번호	요구사항	설명
NFR-1	상태 일관성	LLM 출력이 시스템 확정 상태를 임의로 바꿀 수 없어야 한다.
NFR-2	세계관 정합성	NPC 부재, 영구 사망, 층간 이동 규칙 등 핵심 세계관 규칙을 위반하지 않아야 한다.
NFR-3	재현 가능한 검증	데이터 참조, 밸런스, 스키마 검증을 자동화하여 수동 점검 의존도를 낮춘다.
NFR-4	응답성	모바일 사용자가 대기 중임을 인지할 수 있도록 SSE 스트리밍으로 서사를 점진 표시한다.
NFR-5	비용 통제	LLM 호출 횟수, 토큰 사용량, 재생성 빈도를 기록하고 메모리 주입량을 관리한다.
NFR-6	확장성	더 넥서스 내부의 층, 몬스터, 장비, 직업, 시설 데이터를 코드 변경보다 데이터 추가 중심으로 확장할 수 있게 한다.
NFR-7	유지보수성	게임 데이터는 YAML SSoT, 코드 접근은 DataBridge로 통일하여 데이터 불일치를 줄인다.
NFR-8	관측 가능성	LLM 호출, guardrail rejection, 전투 결과, SSE 이벤트, 이미지 생성 상태를 추적 가능한 로그로 남긴다.

3.4. 입출력 명세

Table 4: 주요 모듈별 입력과 출력

모듈	입력	출력
GameLoop	사용자 선택, 세션 상태	다음 장면 처리 결과
CombatService	캐릭터 스탯, 몬스터 데이터, 활동 유형	전투 결과, HP 변화, 보상
SceneEngine	시스템 판정, 캐릭터 상태, 메모리, 세계관	LLM 프롬프트, 서사 생성 요청
LLM Provider	프롬프트, 출력 스키마	구조화된 장면 서술 JSON
StateGuardrail	LLM 출력, 현재 상태, 규칙 데이터	검증 결과, rejection 사유, 시스템 진실 강제 여부
MemorySystem	장면 결과, 중요도 평가	작업 기억, 에피소드 기억, 의미 기억
HyperGraph	플레이어 만남, 관계 이벤트	관계 그래프, 관련 플레이어 컨텍스트
Scene Image Service	장면 서술, 이미지 생성 설정	장면 이미지 생성 상태, 이미지 조회 URL
Client	API 응답, SSE 스트림	화면 렌더링, 사용자 입력

4. 시스템 설계

4.1. 전체 아키텍처

전체 구조는 결정론적 연산 계층과 LLM 서술 계층으로 나뉜다. 결정론적 연산 계층은 캐릭터 상태, 전투, 아이템, 경험치, 보상, 저장을 담당한다. LLM 서술 계층은 시스템이 확정된 결과를 자연어 장면으로 변환한다.

```

Client (Streamlit current / mobile target)
| REST + SSE
FastAPI
|
GameLoop
|-- CombatService / Character / Inventory / Save
|-- SQLAlchemy -> Supabase PostgreSQL
|-- DataBridge -> YAML Single Source of Truth
|-- SceneEngine -> Gemini structured output
|-- MemorySystem -> 4-layer context
|-- HyperGraph -> relationship context
|-- SceneImageService -> scene image generation
`-- StateGuardrail -> validation and rejection feedback

```

Figure 1: 전체 시스템 아키텍처 개요

이 구조에서 LLM은 읽기 전용 서술자에 가깝다. LLM이 “전설 장비를 획득했다”고 문장을 만들 수는 있지만, 해당 장비가 시스템 데이터에 존재하고 이번 장면에서 획득 가능한 경우가 아니면 실제 인벤토리에 반영되지 않는다. 반대로 전투 시스템이 HP 감소와 보상을 확정하면, LLM은 그 결과를 바탕으로 장면을 표현한다.

장면 생성은 2단계로 나뉜다. 1단계는 플레이어에게 보일 서술, 대화, 액션, 이미지 프롬프트를 생성하고, 2단계는 1단계 서술에서 시스템 상태 변화만 구조화하여 추출한다. 이 분리는 LLM이 자연스러운 문장을 생성하면서도, 실제 상태 변경은 별도 검증 계층을 통과하도록 만들기 위한 핵심 설계이다.

4.2. 결정론적 연산-서술 분리

본 과제의 핵심 설계 원칙은 시스템 권위 영역과 서술 자유 영역을 분리하는 것이다.

Table 5: 시스템 권위 영역과 서술 자유 영역

영역	담당 주체	설명
HP/MP 변화	계산 엔진	전투, 회복, 스킬 결과로만 변경된다.
전투 피해량	CombatService	몬스터, 직업, 장비, 확률 공식으로 계산한다.
장비와 아이템	DataBridge, Inventory	YAML 데이터와 인벤토리 상태에 존재해야 한다.
레벨과 경험치	성장 시스템	경험치 보상과 성장 공식에 따라 갱신한다.
장면 문장	LLM	감정, 분위기, 대화, 액션 묘사를 생성한다.
인물 반응	LLM + Graph	관계 그래프와 메모리를 근거로 생성한다.

이 분리는 CQRS 패턴과 유사하다. 상태 변경 명령은 계산 엔진이 독점하고, LLM은 확정된 상태를 읽어 서술하는 역할을 맡는다. 이로써 LLM 환각이 발생하더라도 실제 게임 상태로 전파되는 범위를 제한할 수 있다.

4.3. 다계층 검증 구조

LLM 출력은 한 번의 검증으로 충분하지 않다. 본 시스템은 다음 계층을 순차적으로 적용한다.

1. 출력 스키마 검증: LLM 출력이 사전에 정의된 JSON 구조를 만족하는지 확인한다.
2. 상태 변화 검증: HP, MP, 아이템, 장비, 파티, 전투 정보가 현재 상태와 충돌하지 않는지 확인한다.
3. 세계관 규칙 검증: NPC 등장, 로그아웃, 부활, 잘못된 층간 이동 같은 금지 패턴을 탐지한다.
4. 관계 검증: 서술에 등장한 플레이어가 encountered players 구조와 일치하는지 확인한다.
5. 메모리 검증: 장기 기억으로 승격될 정보가 현재 사건과 모순되지 않는지 확인한다.
6. 거부 피드백: 검증 실패 시 rejection 사유를 다음 턴 시스템 컨텍스트에 주입하여 같은 위반이 반복되지 않도록 한다.

StateGuardrail은 이 구조의 중심 모듈이다. 착수 시점 기준 `src/game/state_guardrail.py`는 2,474줄이며, 아이템, 태그, HP/MP, 전투 정보, 파티, 장비, 만남, 세계관 규칙, 시간, 메모리, 감정 태그, 가치관 변화 등을 검증한다. 서술 본문은 조용히 치환하지 않고 rejection과 warning으로 가시화하며, 전투 결과나 사망 판정처럼 시스템이 확정한 값은 시스템 진실을 우선한다.

4.4. YAML SSoT와 DataBridge

게임 데이터는 코드에 하드코딩하지 않고 YAML 파일로 관리한다. 전투 공식, 몬스터, 직업, 장비, 스킬, 층별 설정, 세계관 데이터가 각각 YAML로 선언되며, DataBridge가 단일 조회 허브 역할을 한다.

이 방식의 장점은 다음과 같다.

- 게임 밸런스 조정과 코드 수정의 책임을 분리할 수 있다.
- 몬스터, 장비, 직업 같은 콘텐츠 데이터를 검증 스크립트로 일괄 검사할 수 있다.
- LLM 프롬프트에 주입되는 세계관 정보와 시스템 계산에 쓰이는 데이터의 출처를 통제할 수 있다.
- 새 데이터 경로가 생겨도 DataBridge를 통해 접근하도록 강제함으로써 중복 로직을 줄인다.

4.5. 메모리 시스템

LLM 기반 장기 플레이에서 가장 큰 문제는 컨텍스트 창 의 한계이다. 모든 과거 장면을 프롬프트에 넣을 수 없으므로, 중요도에 따라 기억을 압축하고 승격하는 구조가 필요하다. 본 과제는 Atkinson-Shiffrin 기억 모델을 참고해 4계층 메모리 시스템을 사용한다.

Table 6: 4계층 메모리 구조

계층	수명	역할
감각 기억	1턴	현재 턴의 즉각적 입력과 출력을 임시 보존한다.
작업 기억	1씬 이상	현재 장면의 목표, 등장인물, 직전 사건을 유지한다.
에피소드 기억	여러 에피소드	주요 사건과 관계 변화를 요약해 저장한다.
의미 기억	영구	캐릭터 프로필, 세계관 규칙, 장기 관계 정보를 유지한다.

메모리 시스템은 단순 요약 저장소가 아니라, LLM 입력을 관리하는 비용 통제 계층이기도 하다. TokenBudgetAllocator는 프롬프트에 들어갈 기억량을 조절하고, ImportanceScorer는 어떤 사건을 장기 기억으로 승격할지 평가한다.

4.6. 하이퍼그래프 관계 엔진

텍스트 RPG에서 다른 플레이어와의 관계는 단순한 1:1 친구 목록으로 표현하기 어렵다. 한 사건에는 여러 플레이어, 장소, 아이템, 길드, 몬스터, 세계 상태가 동시에 관여한다. 따라서 본 과제는 일반 그래프가 아니라 다자 관계를 표현할 수 있는 하이퍼그래프를 사용한다.

하이퍼그래프 엔진은 노드와 하이퍼엣지로 구성된다. 노드는 플레이어, 다른 플레이어, 장소, 아이템, 이벤트, 길드, 몬스터 타입, 스킬, 세계 상태 등을 나타낸다. 하이퍼엣지는 여러 노드를 동시에 연결하고, 각 노드의 역할과 관계 강도, 관련 memory id를 저장한다.

이 구조는 다음 기능에 활용된다.

- 현재 위치와 과거 관계를 기반으로 재등장 가능성이 높은 플레이어 후보를 컨텍스트로 제공한다.
- 특정 플레이어가 주인공에 대해 알고 있는 정보를 조회한다.
- 공유 사건을 통해 관계 맥락을 LLM 프롬프트에 주입한다.
- StateGuardrail이 서술 속 등장인물의 직업, 레벨, 관계 일관성을 확인할 근거를 제공한다.

4.7. 장면 이미지 생성 보조 계층

본 과제의 핵심 출력은 텍스트 서술이지만, 실제 애플리케이션 경험에서는 장면 이미지도 함께 제시할 수 있다. 현재 구조에서는 LLM 스키마에 `image_prompt` 필드를 포함하고, 서버의 SceneImageService가 서술 텍스트를 이미지 생성 요청으로 연결한다. 이미지 생성은 게임 상태의 권위 원천이 아니며, 텍스트 서술과 시각 프롬프트가 같은 장면 사실을 가리키도록 관리하는 보조 출력 계층으로 둔다.

5. 모바일 애플리케이션 설계

5.1. 모바일 앱의 역할

모바일 앱은 본 과제의 핵심 아키텍처가 실제 사용자 경험으로 동작함을 증명하는 인터페이스이다. 현재 구현체에는 REST API 호출과 SSE 이벤트 처리를 검증하는 Streamlit 클라이언트가 있으며, 별도로 Flutter/HX 기반 화면 카탈로그와 디자인 시스템 산출물이 준비되어 있다. 졸업과제 산출물의 모바일 앱은 이 두 축을 결합하여 서버의 플레이 런타임을 모바일 사용 경험으로 옮기는 표면이다.

모바일 구현의 기술 핵심은 단순 화면 제작이 아니라 클라이언트-서버 통신 계층이다. REST 요청/응답과 SSE 이벤트 스트림을 같은 플레이 턴 단위로 묶고, 서버 이벤트 순서, 중복 수신, 지연,

단절, 세션 복구 상황에서도 클라이언트 상태가 서버의 확정 상태와 어긋나지 않도록 처리해야 한다. HX 디자인 시스템은 긴 서사 텍스트, 상태 패널, 선택지, 오류 피드백을 일관된 모바일 UI로 표시하기 위한 기준으로 사용한다.

졸업과제 기간의 모바일 구현 범위는 모든 부가 시스템을 완성하는 것이 아니라, 핵심 플레이 루프를 안정적으로 제공하는 데 둔다. 즉, 현재 캐릭터 생성 위자드의 입력 항목, 프롤로그 장면의 시작 무기 선택, 장면 서술, 선택지 선택, 상태 표시, 인벤토리/장비 표시, 장면 이미지 표시, 세이브/로드를 우선 구현한다.

5.2. 주요 화면

Table 7: 모바일 앱 주요 화면

화면	주요 기능	설명
시작 화면	새 게임, 이어하기	세션 생성 또는 기존 세션 로드
캐릭터 생성	이름, 성별, 나이, 진입 Day, 외형/음색, 가치관	플레이 시작에 필요한 정체성과 성향 정보를 입력
프롤로그/무기 선택	프롤로그 서술, 튜토리얼 무기 선택	0층 진입 후 시작 무기와 대응 장비를 선택
장면 화면	서술 스트리밍, 선택지	SSE로 AI 서술을 점진 표시하고 선택지를 제공
장면 이미지	이미지 생성 상태, 이미지 조회	서버가 제공하는 장면 이미지 생성 상태와 조회 URL을 화면에 반영
상태 패널	HP, MP, 레벨, 직업	시스템이 확정된 캐릭터 상태 표시
인벤토리	아이템 목록, 장비 상태	보유 아이템과 장착 장비 확인
시스템 로그	검증 상태, 오류 안내	개발/시연용으로 guardrail 처리 결과와 네트워크 오류 확인
게임 오버	영구 사망 표시	HP 0 도달 시 캐릭터 삭제와 재시작 안내

5.3. 사용자 흐름

앱 실행

- > 새 게임 / 이어하기
- > 캐릭터 생성
- > 프롤로그 서술과 튜토리얼 무기 선택
- > 에피소드 1 첫 장면 표시
- > 선택지 선택
- > REST 요청으로 서버에 행동 제출
- > 서버에서 전투/상태/서술 처리
- > StateGuardrail 검증
- > SSE 이벤트 수신 및 화면 상태 갱신
- > 장면 이미지 상태 확인과 다음 장면 표시
- > 저장 또는 계속 진행

Figure 2: 모바일 플레이 흐름

6. 현실적 제약사항 분석 및 대책

6.1. LLM 환각

제약: LLM은 프롬프트를 지키도록 유도할 수 있지만, 항상 규칙을 지킨다고 보장할 수 없다. 특히 장기 플레이에서는 이전 장면의 오류가 메모리를 통해 재주입되어 오염이 누적될 수 있다.

대책: 출력 스키마, StateGuardrail, DataBridge 조회, 세계관 정규 검증, 메모리 승격 검증을 결합한다. 검증 실패 시 rejection feedback loop를 통해 다음 턴 프롬프트에 거부 사유를 주입한다.

6.2. 응답 지연과 API 비용

제약: LLM 호출과 장면 이미지 생성은 네트워크와 외부 API에 의존하므로 응답 지연이 발생한다. 재생성 횟수와 이미지 생성 빈도가 늘어나면 비용도 증가한다.

대책: SSE 스트리밍으로 텍스트 서사의 대기 체감을 줄이고, 이미지 생성은 장면 진행과 분리된 비동기 보조 출력으로 처리한다. 메모리 주입량은 토큰 예산으로 관리하며, 검증 실패율, 재생성 횟수, 이미지 생성 상태를 로그로 수집해 비용 증가 원인을 분석한다.

6.3. 텍스트-이미지 일관성

제약: 장면 이미지가 텍스트 서사와 다른 인물, 장소, 장비를 보여주면 사용자 경험의 신뢰성이 떨어진다. 특히 NPC가 없는 세계관, 장비 보유 여부, 몬스터와 층 분위기 같은 규칙이 이미지 프롬프트에도 반영되어야 한다.

대책: 이미지 생성은 LLM 서술의 보조 결과로 두고, 게임 상태의 권위 원천으로 사용하지 않는다. `image_prompt`는 장면 서술과 같은 시스템 컨텍스트에서 생성하며, 주요 인물, 장비, 장소, 세계관 금지 요소가 텍스트와 충돌하지 않는지 검토하는 평가 항목을 둔다.

6.4. 데이터 일관성

제약: 몬스터, 직업, 장비, 스킬, 층별 데이터가 많아질수록 참조 누락과 밸런스 오류가 발생하기 쉽다.

대책: YAML SSoT와 DataBridge를 통해 접근 경로를 통일하고, 데이터 검증 스크립트와 전투 시뮬레이터를 운영한다. 데이터 변경 시 관련 검증을 실행하여 참조 무결성을 확인한다.

6.5. 모바일 연동 범위

제약: 백엔드 시스템 규모에 비해 졸업과제 기간은 제한적이다. 모든 게임 시스템의 모바일 UI를 완성하려 하면 핵심 플레이 루프가 불안정해질 수 있다.

대책: Tier 1 기능을 우선 구현한다. Tier 1은 캐릭터 생성, 프롤로그 장면의 시작 무기 선택, 장면 서술, 선택지, 상태 패널, 인벤토리, 세이프/로드이다. 이 범위 안에서 REST/SSE 이벤트 순서, 중복 수신 처리, 세션 복구, 오류 피드백 UI를 먼저 안정화한다. 길드, 제작, 고급 경제 UI는 중간 이후 확장 또는 향후 계획으로 둔다.

6.6. 시연 환경

제약: 졸업과제 전시 환경에서는 네트워크 상태, API 키, 모바일 빌드, 서버 실행 환경 문제가 발생할 수 있다.

대책: 실제 앱 시연 외에 사전 녹화 영상, 로컬 서버, 시연용 세션 데이터, guardrail 로그 캡처를 준비한다. 심사위원에게는 정상 플레이와 함께 환각 검증 로그를 보여주는 기술 시연을 병행한다.

7. 추진 체계 및 일정

7.1. 개발 단계

Table 8: 추진 일정

기간	주요 작업	산출물
2026년 5월	착수보고서 작성, 모바일 앱 구조 확정, REST/SSE 이벤트 계약 정리	착수보고서, 모바일 화면 설계, API 연동 명세
2026년 6월	Flutter/HX 기본 화면 구현, 캐릭터 생성과 장면 화면 연동, 상태 동기화 프로토콜 구현	앱 알파 버전, REST/SSE 연동 프로토타입
2026년 7월	선택지 진행, 상태 패널, 인벤토리/장비 화면, 네트워크 오류 복구, 장면 이미지 표시 구현	핵심 플레이 루프가 가능한 모바일 앱

기간	주요 작업	산출물
2026년 8월	StateGuardrail 사례 수집, LLM 일관성 검증, 텍스트-이미지 일관성 점검, 데이터 검증 보강	중간보고서 자료, 환각 방지 사례집, 일관성 평가 로그
2026년 9월	단순 프롬프트 방식 대비 2 계층 구조 평가, 통합 테스트, UX 개선, 성능과 비용 측정	베타 데모, 응답 지연/재생성 통계, baseline 비교 결과
2026년 10월 이후	최종보고서, 3분 시연 영상, 전시회 시연 준비	최종보고서, 시연 영상, 전시 데모

7.2. 역할 분담

Table 9: 구성원 역할 분담

구성원	주담당 역할	주요 책임
박찬오	코어 아키텍처 및 결정론적 게임 시스템	기존 코어 아키텍처와 결정론적 게임 시스템의 유지·고도화 및 최종 통합을 담당한다. 게임 루프, 상태 전이, 전투 판정, 저장/세션 구조, DataBridge, StateGuardrail, Memory/Graph 계층을 통합 관리하고, 서버 API의 상태 변경 경계, 데이터 무결성, 밸런스, 팀원 구현분의 통합 리뷰를 책임진다.
김동현	모바일 클라이언트 통신 및 실시간 플레이 런타임	Flutter 기반 모바일 클라이언트와 클라이언트-서버 통신 계층을 구현한다. REST 요청/응답, SSE 이벤트 스트림, HX 디자인 시스템 기반 플레이 화면, 메시지 순서와 먹등성, 세션 복구, 네트워크 지표 로깅, 모바일-서버 통합 테스트를 담당한다.
신승훈	AI 엔지니어링 및 생성 모델 일관성	Narrative/State 2계층 생성 구조, structured output, prompt contract, StateGuardrail 검증 조건을 점검한다. LLM 출력의 상태 불일치, 아이템 환각, NPC 등장, 전투 결과 왜곡, 텍스트-이미지 불일치 사례를 테스트하고 baseline 평가 harness와 로그 분석 파이프라인을 구현한다.

8. 검증 및 평가 계획

8.1. 정량 평가

본 과제는 단순히 앱이 실행되는지 여부만으로 성공을 판단하지 않는다. 다음 정량 지표를 수집한다.

- 테스트 통과 여부와 테스트 파일/케이스 수
- LLM 출력 rejection 발생률과 같은 유형 위반의 재발률
- 장면 생성 평균 응답 시간과 SSE 최초 토큰 도달 시간
- 단순 프롬프트 방식 대비 2계층 생성 구조의 rejection 발생률, 토큰 사용량, 응답 지연 비교

- 전투 시뮬레이터 기반 생존률, 평균 전투 턴 수, 보상 분포
- YAML 참조 무결성 검증 통과 여부
- 텍스트 서술과 이미지 프롬프트 사이의 주요 객체, 장소, 장비 일치율
- 모바일 핵심 흐름의 성공률: 캐릭터 생성, 프롤로그 무기 선택, 장면 생성, 선택지 진행, 저장/로드, 세션 복구

8.2. 정성 평가

정성 평가는 다음 기준으로 수행한다.

- 서술이 시스템 판정 결과와 자연스럽게 연결되는가
- 같은 세계관 규칙이 장기 플레이에서도 유지되는가
- 플레이어가 AI 생성 서사의 변화를 체감하는가
- 장면 이미지가 텍스트 서사와 같은 상황, 인물, 장비를 가리키는가
- 모바일 UI가 텍스트 RPG의 긴 문장을 읽고 선택하기에 적합한가
- 환각 방지 구조가 코드와 로그로 설명 가능한가

8.3. 주요 테스트 계획

Table 10: 검증 계획

검증 대상	방법	성공 기준
StateGuardrail	tests/test_state_guardrail.py, tests/test_scene_engine_guardrail_propagation.py 실행	금지 상태 변경과 세계관 위반을 rejection 처리
데이터 무결성	scripts/validate_data.py 및 validate 계열 스크립트 실행	참조 누락, 잘못된 등급/레벨, 스킬 참조 오류 없음
전투 밸런스	scripts/combat_simulator.py 배치 실행	레벨대별 생존률과 보상 분포가 의도 범위 내
메모리/그래프	tests/test_memory_compaction.py, tests/test_graph_context.py 실행	기억 승격과 관계 컨텍스트 조화가 의도대로 동작
2계층 생성 구조	baseline 평가 harness와 playbot 로그 비교	단순 프롬프트 방식 대비 상태 불일치와 반복 rejection 감소
텍스트-이미지 일관성	장면 로그와 image_prompt 샘플 점검	주요 인물, 장비, 장소, 세계관 금지 요소가 텍스트와 충돌하지 않음
API/SSE 연동	FastAPI 라우트 테스트와 클라이언트 통합 테스트	프롤로그 무기 선택, 장면 생성, 선택지 진행, 저장/로드, 이벤트 순서, 중복 수신, 세션 복구 처리 성공

검증 대상	방법	성공 기준
시연 안정성	사전 리허설과 고정 세션 백업	네트워크 장애 대비 백업 시나리오 확보

9. 기대 효과 및 향후 발전 방향

9.1. 기대 효과

본 과제 of 기대 효과는 다음과 같다.

- LLM 기반 게임에서 상태 오염을 줄이는 구조적 설계 사례를 제시한다.
- 텍스트 RPG의 콘텐츠 생산 비용을 낮추면서도 장기 플레이 맥락을 유지하는 방법을 검증한다.
- 2계층 생성 구조와 guardrail rejection feedback을 통해 프롬프트만 사용하는 방식보다 설명 가능한 일관성 제어 방법을 제시한다.
- 텍스트 서사와 이미지 프롬프트를 함께 다루는 멀티모달 생성 환경에서 상태 권위를 보존하는 설계 기준을 제공한다.
- 게임 도메인뿐 아니라 교육, 시뮬레이션, 대화형 훈련 시스템 등 상태 일관성이 중요한 LLM 응용에 적용 가능한 검증 패턴을 도출한다.
- 모바일 앱을 통해 서버 아키텍처가 실제 사용자 경험으로 연결됨을 증명한다.

9.2. 향후 발전 방향

착수보고서 이후에는 다음 방향으로 확장한다.

- 현재 Streamlit 클라이언트에서 검증한 REST/SSE 흐름을 바탕으로 모바일 앱의 핵심 플레이 루프를 완성하고 실제 모바일 기기에서 시연한다.
- StateGuardrail의 rejection 사례를 유형화하여 보고서와 발표에서 기술적 근거로 활용한다.
- 하이퍼그래프와 메모리 시스템의 연동 효과를 장기 세션 로그로 분석한다.
- 층, 몬스터, 장비, 직업, 시설 데이터를 추가하면서 DataBridge와 검증 스크립트가 확장 규모를 감당하는지 점검한다.
- 최종보고서에서는 실제 테스트 결과, 응답 시간, 비용, 환각 차단 사례, 텍스트-이미지 일관성 사례를 정량적으로 제시한다.

10. 결론

본 과제는 LLM의 생성 능력을 게임 서사에 활용하되, 게임 상태와 세계관의 진실은 결정론적 시스템이 통제하도록 설계한다. 이를 위해 계산 엔진과 서술 엔진을 분리하고, 2계층 생성 구조, StateGuardrail, YAML SSoT, DataBridge, 4계층 메모리, 하이퍼그래프 관계 엔진, 장면 이미지 보조 계층을 결합한 다계층 검증 아키텍처를 구축한다.

착수 시점에는 백엔드, 데이터, 검증 클라이언트, Flutter/HX 화면 기반이 구축되어 있으며, 졸업과제 기간에는 이를 모바일 앱과 통합하고, 통신 안정성, 생성 모델 일관성, 검증 로그, 테스트 결과를 통해 신뢰성 보장 효과를 입증하는 데 집중한다. 최종 산출물은 단순한 AI 게임 데모가 아니라, LLM 서사 생성 시스템에서 환각을 제어하기 위한 실제 구현 기반의 설계 사례가 될 것이다.