

LLM 서사 생성 시스템의 환각 방지 아키텍처 설계 및 구현



202155557 박찬오 opark001@pusan.ac.kr

202155524 김동현 sua3801@pusan.ac.kr

202355637 신승훈 uitopia04@pusan.ac.kr

지도교수 박진선

목 차

1. 서론.....	1
1.1. 연구 배경.....	1
1.2. 기존 문제점	2
1.3. 연구 목표와 개발 범위	3
1.4. 연구 질문과 성과의 판단 기준	4
2. 연구 배경.....	5
2.1. 생성형 게임과 세계 내부의 일관성	5
2.2. 경험을 활용하는 에이전트 기억	5
2.3. 그래프를 이용한 관계와 경험의 연결.....	6
2.4. 생성과 실행의 분리	6
2.5. 생성 결과의 검증	7
2.6. 평가 방법과 본 과제의 위치	7
3. 연구 내용	9
3.1. 게임 구성과 사용자 경험.....	9
3.2. 전체 시스템 구조.....	10
3.3. 규칙 데이터와 상태 모델.....	11
3.4. 행동 처리와 상태 확정	12
3.5. 결정적 실행이 제공하는 상태와 사건.....	13
3.6. 장면 생성과 동적 맥락	14
3.7. 선택 생성과 정산 연결	15
3.8. 생성 검수와 상태 보호	16
3.9. 4계층 기억의 저장과 활용	19
3.10. 기억 입력 예산과 중복 관리	21
3.11. 관계 하이퍼그래프와 인물의 지속성	23

3.12.	Flutter 화면과 정보 표현	25
3.13.	서버 통신과 비동기 처리	29
3.14.	자동 저장과 실패 복구	30
3.15.	파티 수락의 전체 처리 사례	31
3.16.	설계 대안과 통합 과정의 주요 결정	31
3.17.	개발 단계와 범위의 변화	33
3.18.	구성원별 역할과 담당 범위	34
3.19.	산업체 멘토 의견과 반영	35
4.	연구 결과 분석 및 평가	37
4.1.	평가 목적과 실험 구성	37
4.2.	최종 평가 자료의 선정과 관측 범위	39
4.3.	선택 정산과 상태 일치	42
4.4.	상태 보호와 서술의 정확성	43
4.5.	기억 전달의 정상 사례와 오류 사례	46
4.6.	장기 기억 입력 비교	48
4.7.	검출기 성능과 후보 차단	51
4.8.	운영 비용과 적용 범위	54
4.9.	종합 평가와 계획 대비 수행 범위	54
5.	결론 및 향후 연구 방향	56
5.1.	연구 결론	56
5.2.	향후 연구 방향	57
6.	참고 문헌	58

1. 서론

1.1. 연구 배경

텍스트 RPG에서 플레이어는 문장을 읽고 행동을 선택하면서 게임 세계를 경험한다. 같은 장소에서도 누구를 만났는지, 어떤 약속을 했는지, 이전 전투에서 무엇을 잃었는지에 따라 이후의 대화와 판단이 달라질 수 있다. 이러한 경험을 고정된 대사와 분기만으로 제작하려면 상황별 콘텐츠를 미리 작성해야 한다. 등장인물과 사건의 조합이 늘어날수록 제작해야 하는 분기도 증가한다. 대규모 언어 모델은 현재 상황에 맞는 장면과 대화를 생성할 수 있으므로, 플레이어의 선택에 반응하는 텍스트 게임을 구현하는 데 유용하다.

그러나 자연스러운 문장을 생성하는 능력만으로 지속적으로 플레이할 수 있는 게임을 구성하기는 어렵다. 게임에는 이전 행동으로 확정된 사실이 존재한다. 사용하지 않은 아이템이 사라져서는 안 되며, 수락하지 않은 인물이 파티에 들어와서도 안 된다. 전투에서 남은 생명력은 다음 전투의 조건이고, 이전에 만난 인물과의 관계는 다음 대화의 맥락이다. 생성 결과가 이러한 사실과 충돌하면 플레이어는 무엇을 믿고 선택해야 하는지 알기 어려워진다.

자연어 생성의 환각은 입력이나 사실적 근거와 부합하지 않는 출력을 포함한다[1]. 허구의 게임에서는 현실에 존재하지 않는 장소나 사건을 창작했다는 사실 자체가 오류는 아니다. 본 과제에서 해결하려는 문제는 생성된 서술이 게임 내부의 규칙, 확정 상태, 이미 경험한 사건과 어긋나는 경우이다. 예를 들어 다른 인물이 새로운 제안을 하는 것은 창작 가능한 사건이지만, 실제 구매 처리가 없는데 물건을 구매했다고 확정하는 것은 상태와 서술의 모순이다.

본 연구에서는 이러한 문제를 다루는 LLM 기반 싱글 플레이어 텍스트 RPG Hallucination을 설계하고 구현하였다. 게임의 배경은 거점인 0층과 1~100층의 공략 공간으로 이루어진 가상 세계 '더 넥서스'이다. 플레이어는 직업을 선택하여 탐험과 전투를 수행하고, 다른 인물과 대화하며 관계를 형성한다. MMORPG 형태의 세계를 표현하지만 실제 사용자는 한 명이며, 다른 플레이어의 행동과 대화는 시스템과 AI가 시뮬레이션한다. 본 과제는 생성 모델의 서술 능력을 활용하면서 게임의 규칙과 결과를 일관되게 유지하는 소프트웨어 구조를 만드는 데 초점을 둔다. 구현한 시스템은 자연어 선택을 실제 게임 동작에 연결하고, 이전 경험을 후속 생성에 공급하며, 검수 결과에 따라 장면과 상태의 확정을 관리한다. 이를 Python 서버와 Flutter 앱에 통합하여 플레이어가 장면 읽기, 선택, 상태 확인과 재개를 수행할 수 있도록 하였다.

1.2. 기존 문제점

첫 번째 문제는 서술과 게임 상태의 불일치이다. 모델이 전투 결과, 회복, 아이템 획득과 같은 내용을 자유롭게 작성하고 그 문장을 다시 상태에 적용하면, 표현상의 오류가 실제 게임 결과로 이어질 수 있다. 반대로 수치는 프로그램이 관리하더라도 모델이 다른 수치를 암시하는 문장을 보여주면 플레이어가 인식하는 상태는 잘못된다. 따라서 상태 계산과 문장 검증을 각각 설계해야 한다.

두 번째 문제는 장기적인 맥락 유지이다. 모든 과거 장면을 계속 입력하면 문맥의 길이와 처리 비용이 증가한다. 중요한 사실만 요약하면 직전 대화의 구체적인 상황이 사라질 수 있고, 원문을 반복적으로 제공하면 과거의 표현이 새 장면에서도 되풀이될 수 있다. 또한 잘못된 문장이 기억으로 저장되면 이후 생성의 근거로 사용되어 오류가 지속된다. 최근 장면의 연속성과 장기 경험의 보존을 함께 고려한 기억 구조가 필요하다.

세 번째 문제는 자연어 선택과 실제 동작의 연결이다. 플레이어에게 “함께 출발한다”는 선택을 보여주었다면 이후 장면에서 그 행동이 수행되어야 한다. 정식 파티 가입이나 이동이 포함되어 있다면 해당 명단과 위치도 함께 바뀌어야 한다. 이를 위해 선택 문구에 나타난 대상, 프로그램이 적용하는 효과, 다음 장면에서 설명할 완료 사실이 같은 행동을 가리켜야 한다. 자연어의 의미와 정산 정보를 연결하는 구조가 필요한 이유이다.

네 번째 문제는 생성 실패를 포함한 플레이의 지속성이다. 모델 응답은 형식 오류나 참조 오류로 사용할 수 없을 수 있고, 통신이 중단될 수도 있다. 이때 일부 자원만 소비되거나 이미 지급한 보상을 다시 지급하면 게임 상태가 손상된다. 생성, 검수, 상태 확정, 저장, 화면 표시의 순서를 명시적으로 관리해야 한다. 이러한 요구는 생성 모델 하나의 성능과 별개로 애플리케이션 전체에서 해결해야 한다.

개발 중 30장면 연속 플레이에서는 MP가 가득 찬 상태인데 고갈되었다는 서술이 이후 선택과 기억에 재사용되었고, 근거 없는 위협이 ‘숲의 주인’ 전투로 확대되어 후반 15장면의 맥락에 남았다. 마지막 구간에는 대응하는 결정적 전투 사건이 없는데도 전투·추격 서술이 이어졌다. 이러한 사례는 처음 생긴 오류가 이후 생성의 전제가 되는 문제를 보여준다. 장면을 끝까지 실행한 횟수만으로 일관성을 평가할 수 없는 이유이다.

상태와 표현의 충돌은 문맥을 기준으로 판단한다. 체력이 가득 찼더라도 긴장이나 주관적인 피로를 표현할 수 있으므로 ‘탈진’과 같은 단어의 존재만으로 수치 오류를 확정하지 않는다. 실제 자원 고갈이나 회복, 피해와 같이 시스템 상태를 보증하는 주장인지, 인물의 감정이나 말인지 구분해야 한다.

1.3. 연구 목표와 개발 범위

본 과제의 목표는 상태가 누적되는 LLM 서사 시스템에서 환각의 발생, 탐지, 상태 반영을 분리하여 통제하는 아키텍처를 설계하고 구현하는 것이다. Hallucination의 텍스트 RPG는 이 구조를 적용하고 측정하는 실험 환경이다. 체력·마력·소지금·소유물·파티 명단에는 시스템이 확정한 값이 있으므로, 잘못된 문장이 생성되었는지와 실제 값이 오염되었는지를 따로 확인할 수 있다.

게임의 수치와 정식 상태는 프로그램이 확정한다. LLM은 현재 상황과 확정된 결과를 바탕으로 사건의 전개, 대화, 인물의 반응을 작성한다. 이때 열린 서사 행동을 모두 고정된 명령 목록으로 제한하지 않는다. 협상이나 질문처럼 즉각적인 수치 변화가 없는 선택도 다음 이야기의 방향을 바꿀 수 있기 때문이다. 정산이 필요한 부분은 명시적인 실행 정보와 연결하고, 그 밖의 의미는 자연어로 전달한다.

개발 결과물은 Python 기반 서버와 Flutter 앱이다. 서버에는 게임 실행, 규칙 데이터 연동, 기억과 관계 검색, 모델 호출, 검수, 세션 저장 기능을 구현하였다. 앱에는 장면 읽기와 선택, 캐릭터와 장비 확인, 인물 관계와 시설 조작 등 플레이에 필요한 화면을 구성하였다. 과제의 핵심은 책임 분리, 4계층 기억, 관계 하이퍼그래프, AI 플레이어·세계 맥락 공급, 다계층 검증과 상태 보호, 앱·서버·저장 연동이다. 자동 평가와 로그 분석은 이 구조의 동작과 결과를 확인하는 데 사용하였다. 전투·아이템·이동·성장 기능은 상태의 정답과 실행 사건을 제공하는 적용 환경으로 설명한다. 자동 플레이 평가는 0.1층과 1차 직업을 중심으로 수행하였다.

본 과제의 기술적 기여는 생성 입력, 실행 권한, 검수 이후의 적용을 하나의 행동 처리 흐름으로 연결한 데 있다. 각 구성요소가 해결하는 문제와 구현 결과는 다음과 같다.

표 1. 핵심 기여와 구현 성과

핵심 기여	해결한 구현 문제	구현 성과와 확인 근거
자연어 선택과 상태 정산의 연결	선택 문구와 실제 실행 대상이 어긋나는 문제	수락 문구와 실행 정보를 같은 자료에서 구성. 파티 수락의 표시·후속 장면·실제 명단 연결(제3.15절)
경험을 공급하는 기억·관계 구조	최근 대화와 장기 경험을 함께 제공해야 하는 문제	4계층 기억과 관계 하이퍼그래프 구현. 원문→요약→후속 입력의 전달 관측 및 별도 장기 기억 입력 비교 수행
생성 검수와 상태 확정의 연결	잘못된 완료 서술이 상태·기억에 적용되는 문제	구조·참조·의미 검수와 확정·복구 경계 구현. 구매 후보 거절과 상태 보존 사례 확인
앱에서 이어지는 통합 플레이	생성·정산·저장·표시의 진행 지점을 맞추는 문제	Flutter·REST·SSE·세션 저장 연동. 파티 화면 사례와 분리 로드 24회·재개 응답 240필드의 일치 확인

이 네 기여는 하나의 플레이 흐름에서 결합된다. 플레이어는 선택에 따른 정산 결과를 상태에서 확인하고, 함께 겪은 경험을 이후 인물의 반응에서 다시 만난다. 이를 위해 선택의 의미를 실행에 연결하고, 확정된 사건을 기억과 다음 장면에 전달하며, 검수와 저장을 거친 결과를 앱에서 이어 읽도록 한다. 제3장은 각 연결의 설계와 구현을, 제4장은 실행 기록과 비교 실험을 통한 확인 결과를 설명한다.

1.4. 연구 질문과 성과의 판단 기준

본 연구는 세 가지 질문을 다룬다. 첫째, 자유로운 서술을 유지하면서 게임 상태의 변경과 잘못된 후보의 적용을 통제할 수 있는가. 둘째, 최근 대화와 장기 경험을 보존하고 현재 인물과 관련된 경험을 후속 생성에 공급할 수 있는가. 셋째, 이를 선택·결과 확인·재개가 가능한 앱으로 통합할 수 있는가.

각 질문은 선택과 정산의 일치 및 거절 전후 상태, 경험의 후속 입력과 기억 유무 비교, 앱 응답과 저장·재개 결과로 평가한다. 상태 보호와 서술 정확성은 별도로 확인하며, 기능의 작동과 비교 조건에서의 효과를 구분한다. 실험 조건과 일반화 범위는 제4장에서 제시한다.

2. 연구 배경

2.1. 생성형 게임과 세계 내부의 일관성

LLM을 게임에 적용할 때는 무엇을 생성하고 무엇을 이미 정해진 사실로 취급할지 구분해야 한다. CALYPSO는 테이블톱 RPG의 진행자를 보조하여 게임 정보를 간결하게 제시하고 장면 구성의 아이디어를 제공하는 시스템이다[2]. 이 연구는 게임의 맥락을 자연어 생성과 연결할 수 있음을 보여준다. 동시에 인간 진행자가 내용을 선택하고 발전시키는 사용 환경이라는 점에서, 생성 결과를 곧바로 앱에서 소비하는 본 과제와 차이가 있다.

Hallucination에서는 매 장면마다 사람이 생성 결과를 편집하지 않는다. 플레이어가 선택하면 서버가 다음 장면을 구성하고 결과를 전달한다. 따라서 창작 지원 도구에서 사람이 말하는 확인과 실행의 일부를 소프트웨어가 담당해야 한다. 게임 규칙으로 판단할 수 있는 수치와 상태는 프로그램에서 확인하고, 문장의 의미가 현재 사실과 맞는지 별도의 검수 대상으로 삼는다.

이 구분은 창작의 범위를 없애기 위한 것이 아니다. 같은 전투 결과에서도 인물의 태도, 대화, 감각적 묘사, 다음 제안은 다양하게 생성될 수 있다. 일관성의 대상은 이러한 표현의 동일성이 아니라, 그 표현이 기대는 사실이다. 생성된 장면이 규칙에 맞다는 것과 그 장면이 흥미롭다는 것 역시 서로 다른 평가 질문이다. 본 과제는 두 질문을 연결하되 하나의 수치로 대체하지 않는다.

2.2. 경험을 활용하는 에이전트 기억

Generative Agents는 자연어로 기록한 경험을 검색하고, 경험을 반영하여 더 높은 수준의 내용을 형성하며, 이를 이후 계획과 행동에 사용하는 구조를 제시하였다[3]. 관련성, 최신성, 중요도는 어떤 기억을 현재 입력에 제공할지 판단하는 요소이다. 이는 대화 이력을 단순히 연결하는 방식보다 경험의 선택과 활용을 명시적으로 다룬다는 점에서 본 과제와 관련된다.

MemGPT는 모델이 직접 읽는 문맥과 외부 저장소를 구분하고, 함수 호출을 통해 필요한 정보를 현재 문맥으로 옮기는 구조를 제시하였다[4]. 작업 중 유지할 정보와 장기간 보관할 정보를 나누어 제한된 입력 공간을 관리한다. 본 과제도 모든 경험을 매번 입력하지 않고 계층별로 선택한다. 다만 현재 구현에서는 모델이 임의로 저장 계층을 조작하도록 맡기는 대신, 장면 완료와 기억 처리 시점에 따라 프로그램이 저장과 승격을 관리한다.

이러한 연구를 바탕으로 기억을 단순한 대화 보관함이 아니라 현재 생성에 필요한 경험을 공급하는 구성요소로 볼 수 있다. Hallucination에서는 직전 장면을 읽는 데 필요한 원문과, 여러 장면 이후에도 보존할 요약의 역할을 구분하였다. 최근 대화는 구체성이 중요하고, 오래된 경험은 현재 관계나 판단에 필요한 핵심 사실이 중요하기 때문이다. 각 계층의 이름만 구분하는 데 그치지 않고 저장되는 정보의 형태와 입력 예산도 다르게 구성하였다.

2.3. 그래프를 이용한 관계와 경험의 연결

AriGraph는 텍스트 게임 환경에서 의미 지식과 일화 기억을 결합한 그래프를 구축하고 갱신하여 에이전트의 계획과 행동을 지원한다[5]. 하나의 관찰에서 얻은 사실과 그 사실이 속한 경험을 함께 연결함으로써, 개별 문장의 유사도만으로 찾기 어려운 관련 정보를 탐색한다. 텍스트 게임이라는 적용 환경과 기억의 구조화라는 측면에서 본 과제와 가까운 비교 대상이다.

Hallucination에서는 인물과 장소, 집단, 경험이 여러 방식으로 연결된다. 두 사람이 알고 있다는 관계만으로는 어떤 장소에서 어떤 사건을 함께 겪었는지 충분히 표현할 수 없다. 하나의 사건에 여러 인물이 참여하는 경우에는 사건 전체의 맥락을 유지할 필요도 있다. 이를 위해 여러 노드를 하나의 간선으로 연결할 수 있는 하이퍼그래프를 사용하였다.

본 과제의 기억과 그래프는 역할이 다르다. 기억 계층은 경험의 내용과 보존 수준을 관리하고, 그래프는 관련 인물과 공동 경험을 찾는 연결 구조를 제공한다. 검색한 정보는 다시 장면 생성의 입력이 된다. 이 과정에서 과거의 경험이 현재 자원이나 정식 명단을 덮어쓰지 않도록, 현재 상태는 별도의 근거로 함께 제공한다. 그래프 검색 자체가 기억 내용의 사실성을 보장하는 것은 아니므로, 내용의 검수와 상태 관리는 별도로 유지한다.

2.4. 생성과 실행의 분리

ReAct는 언어 모델의 추론과 환경에 대한 행동을 번갈아 수행하면서 외부 관찰을 다음 판단에 활용하는 접근이다[6]. 모델이 작성한 내용과 외부 환경에서 실제로 일어난 결과를 연결한다는 점에서, 생성 모델을 독립적인 문장 작성기로만 사용하는 방식과 차이가 있다. 본 과제에서도 모델이 기대하거나 묘사한 결과와 시스템이 실제로 확인한 결과를 구분한다.

예를 들어 파티 가입 제안은 인물의 대화로 생성될 수 있지만, 가입 완료는 프로그램이 실제 명단을 변경했을 때 성립한다. 전투의 피해와 보상도 마찬가지이다. 프로그램이 계산한 사건을 모델에 전달한 뒤, 모델은 그 사건이 어떻게 경험되었는지를 서술한다. 결정

적이라는 표현은 난수를 전혀 사용하지 않는다는 뜻이 아니다. 같은 초기 상태와 입력, 필요한 난수 조건이 주어졌을 때 정해진 규칙으로 결과를 계산한다는 뜻이다.

본 과제는 모든 자연어 행동을 도구 명령으로 환원하지 않는다. 상대의 의도를 묻거나 제안을 보류하는 선택은 대화와 관계의 맥락을 바꾸지만 반드시 명단이나 수치를 바꾸지는 않는다. 반면 실제 상태가 달라지는 선택에는 실행 대상과 효과를 명확히 연결한다. 이 경계를 두어 자유로운 표현과 게임 규칙의 일관성을 함께 유지하고자 하였다.

2.5. 생성 결과의 검증

SelfCheckGPT는 동일한 주제에 대해 생성한 여러 응답 사이의 일관성을 이용하여 사실 오류를 탐지하는 방법이다[7]. 외부 데이터베이스 없이 모델의 출력들을 비교한다. Chain-of-Verification은 초안 작성, 검증 질문 구성, 질문에 대한 독립적인 답변, 최종 응답 작성의 과정을 통해 오류를 줄이는 접근이다[8]. 두 연구는 생성된 응답을 한 번 더 검토하는 과정의 필요성과 방법을 보여준다.

NeMo Guardrails는 개발자가 정의한 규칙과 실행 흐름을 모델 기반 애플리케이션에 추가하는 도구이다[9]. 논문에는 제공된 근거가 응답을 뒷받침하는지 판정하는 사실 검증 방식도 포함된다. 본 과제에서는 외부 근거에 대한 검증을 게임의 현재 상태와 완료된 사건에 맞게 구체화하였다.

Hallucination의 검수는 응답 형식, 인물과 실행 대상의 참조, 현재 상태와 완료 주장 등을 구분한다. 필수 필드나 참조의 유효성은 프로그램이 검사한다. “회복되었다”, “가입을 마쳤다”와 같은 문장이 실제 사건과 일치하는지는 의미 검수에서 확인한다. 의미 판정은 오류가 있을 수 있으므로, 검수가 존재한다는 이유만으로 모든 환각을 방지했다고 결론짓지 않는다. 동시에 검수가 잘못된 후보를 거절했을 때 그 후보가 화면·기억·상태에 적용되지 않도록 집행하는 것은 프로그램의 책임으로 둔다.

2.6. 평가 방법과 본 과제의 위치

CheckList는 하나의 전체 정확도만으로 모델을 평가하기보다 특정 능력과 기대 동작을 구분하여 검사하는 방법을 제시하였다[10]. 본 과제에서도 선택의 정산, 현재 상태의 설명, 기억의 전달, 실패 후 복구를 서로 다른 질문으로 나누었다. 정상적인 동행 제안과 가입 완료 주장은 겉으로 비슷한 단어를 포함하더라도 기대되는 상태 변화가 다르므로, 문맥과 전후 결과를 함께 확인해야 한다.

τ -bench는 사용자와 도구를 사용하는 에이전트의 상호작용을 평가하며, 종료 시 데이터베이스 상태를 기대 상태와 비교한다[11]. 이 방법은 문장이 자연스럽다는 이유만으로 작업이 성공했다고 판단하지 않도록 한다. Hallucination의 파티 명단이나 위치도 기대 상태와 비교할 수 있다. 그러나 서사의 모든 결과에는 유일한 정답이 있는 것이 아니므로, 상태 비교만으로 장면과 대화의 품질을 평가할 수는 없다.

본 과제의 기여는 이러한 문제를 하나의 플레이 가능한 텍스트 RPG에서 연결한 설계와 구현에 있다. 생성에 필요한 기억을 공급하고, 규칙에 따른 결과를 확정하며, 생성 후보를 검수하고, 통과한 장면을 저장하여 앱에 표시하는 흐름을 구성하였다. 기여의 단위는 새로운 범용 검출 모델보다, 게임 상태를 근거로 생성 입력과 후보 검수, 상태 적용을 연결한 소프트웨어 아키텍처이다. 그 타당성은 구성요소의 처리 조건과 통합 실행 사례, 검출 성능과 실패 사례를 통해 평가한다.

3. 연구 내용


3.1. 게임 구성과 사용자 경험

Hallucination의 플레이는 캐릭터 생성에서 시작한다. 사용자는 1차 직업을 선택하고 0층의 거점에서 첫 상황을 맞는다. 직업은 전투에서 사용할 능력과 장비의 조건에 영향을 주며 이후 성장의 방향이 된다. 세계에는 다른 플레이어가 존재하는 것으로 표현되지만 이들은 실제 접속 사용자가 아니다. 서버가 관리하는 인물 정보와 AI가 생성하는 행동·대화를 통해 MMORPG의 사회적 환경을 구성한다.

주요 플레이 단위는 장면과 선택이다. 장면에는 주변 상황, 인물의 행동과 대화, 전투와 이동의 결과 등이 순서대로 제시된다. 사용자는 장면을 읽은 뒤 현재 상황에 대응하는 선택을 확정한다. 다음 장면은 선택한 행동의 수행과 상대의 반응, 그로 인해 달라진 상황을 보여주고 새로운 판단 지점으로 이어진다. 선택 한 번이 단순한 대화 진행 버튼이 되지 않도록, 선택의 결과를 충분히 읽을 수 있는 단위로 구성하였다.

텍스트를 읽는 흐름과 시스템 기능을 조작하는 흐름은 구분하였다. 장비 장착이나 소모품 사용처럼 대상과 결과가 명확한 조작은 별도 화면에서 제공한다. 이러한 조작을 하기 위해 현재 대화나 선택을 버릴 필요는 없다. 반면 인물과의 협상이나 탐험 방향처럼 이후 전개에 의미가 있는 판단은 주 장면의 선택으로 제공한다. 사용자는 필요할 때 자신의 상태를 확인하고 다시 이야기로 돌아갈 수 있다.

생명력이 0이 되면 해당 캐릭터의 플레이는 종료된다. 임의의 과거 저장 슬롯으로 돌아가 다른 결과를 고르는 구조를 사용하지 않고, 현재 진행을 자동으로 저장하고 이어하는 방식으로 구현하였다. 게임의 영구 사망 규칙과 세션의 기술적인 보존은 구분한다. 사망한 세션은 새 행동을 수행할 수 없으며, 앱에서는 종료된 플레이의 결과를 확인한다.



시스템 정보를 확인한 뒤 같은 이야기의 판단 지점으로 복귀

그림 1. 장면 읽기와 시스템 조작을 연결한 사용자 흐름

3.2. 전체 시스템 구조

시스템은 Flutter 클라이언트, FastAPI 서버, 게임 실행 계층, 생성·검수 계층, 기억·관계 계층, 데이터 저장 계층으로 구성하였다. Flutter는 사용자 입력과 결과 표시를 담당하고, 서버는 세션별로 현재 행동의 처리와 상태를 관리한다. LLM 호출은 서버에서 수행하며 클라이언트가 직접 모델에 게임 상태 변경을 요청하지 않는다.

GameLoop는 세션의 시작과 행동 처리, 선택 생성, 저장과 재개를 연결한다. CombatService와 기능별 실행기는 전투 및 시스템 조작을 처리하고, SceneEngine과 ChoiceEngine은 장면과 선택의 생성을 담당한다. MemorySystem과 관계 그래프는 현재 생성에 필요한 경험과 인물 맥락을 제공한다. 각 구성요소의 결과는 서버의 응답 모델을 통해 앱에 전달한다.

이 구조에서 중요한 것은 모듈의 개수보다 데이터가 이동하는 순서이다. 선택을 받으면 현재 선택인지 확인하고 필요한 정산을 수행한다. 현재 상태와 정산 결과, 직전 장면, 기억과 관계를 조합하여 생성 입력을 만든다. 모델이 반환한 후보를 검수한 뒤 사용할 수 있는 결과만 확정하고 저장한다. 앱은 이 확정 결과를 화면에 표시한다. 실패한 후보가 중간 단계에서 그대로 사용자에게 노출되거나 기억으로 남지 않도록 처리 경계를 둔다.




그림 2. 클라이언트와 게임 실행 및 생성 계층의 구성

표 2. 구성요소와 주요 책임

구성요소	주요 입력	처리와 출력
Flutter	사용자 선택과 서버 응답	장면·상태 표시와 조작 요청
FastAPI와 GameLoop	세션과 행동 요청	실행 순서·동시 접근·확정 상태 관리
규칙 실행 계층	현재 상태와 규칙 데이터	전투·이동·자원·명단의 결과
생성 계층	장면 맥락과 확정 사실	서술·대화·다음 선택 후보
검수 계층	후보와 현재 사실	형식·참조·주장의 수용 여부
기억과 관계	완료 장면과 인물 정보	현재 생성에 필요한 경험
저장 계층	확정 세션과 진행 정보	자동 저장과 재개에 필요한 상태

3.3. 규칙 데이터와 상태 모델

게임의 규칙 데이터는 코드에 분산된 문자열과 숫자로 관리하지 않고 YAML 데이터와 DataBridge를 통해 제공한다. 층과 구역, 직업과 장비, 몬스터와 전투 규칙 등은 실행과 서술에서 함께 참조해야 하는 정보이다. 동일한 데이터가 서로 다른 형태로 중복 관리되면 코드가 허용하는 것과 모델이 설명하는 것이 달라질 수 있으므로, 필요한 데이터를 각 계층에 맞게 전달하는 구조로 구성하였다.

전체 세계 데이터와 현재 장면의 입력은 같은 범위가 아니다. 모델에 모든 층과 모든 인물을 한꺼번에 제공하면 현재 위치와 관련 없는 정보를 사용할 가능성이 생긴다. 장면 입력에는 현재 층과 구역의 환경, 허용되는 활동, 해당 위치의 몬스터와 시설 등 현재 상황에 필요한 내용을 우선 제공한다. 다른 구역이나 층의 정보는 접근 가능성과 공개 범위에 맞추어 제한적으로 사용한다.

플레이어 상태에는 생명력과 마력, 골드, 레벨과 직업, 장착·소유 아이템, 현재 위치, 정식 파티 등의 값이 포함된다. 이 값들은 각 동작의 실행 조건과 결과를 결정한다. 예를 들어 장착은 소유 여부와 직업 호환을 확인해야 하며, 파티 가입은 인물의 생존과 현재 명단, 정원을 확인해야 한다. 모델이 자연어에서 대상을 언급했다는 사실만으로 이러한 조건을 통과한 것으로 처리하지 않는다.

상태 정보와 서사 정보를 분리하되 서로 단절시키지는 않았다. 모델은 현재 상태를 알아야 그에 맞는 장면을 쓸 수 있고, 사용자는 장면 속 상황을 바탕으로 상태를 바꾸는 행동을 선택한다. 이를 위해 현재 값과 완료된 사건을 생성 입력에 함께 제공한다. 현재 생명력이 100이라는 정보와 방금 20의 피해를 받았다는 정보는 서로 다른 역할을 한다. 전자는 다음 행동의 조건이고 후자는 방금 벌어진 일을 설명하는 근거이다.

표 3. 정보의 성격에 따른 관리 방법

정보	관리 주체	장면에서의 사용
층·직업·전투 규칙	게임 데이터와 실행 코드	가능한 환경과 행동의 조건
HP·골드·장비·정식 명단	기능별 정산과 세션 상태	현재 상태 및 완료 결과의 근거
현재 대화와 인물 반응	장면 생성	사용자가 읽는 사건과 관계의 전개
과거 경험의 요약	기억 계층	이전 사건의 맥락 연결
인물·사건의 연결	관계 그래프	재등장과 공유 경험 검색


3.4. 행동 처리와 상태 확정

사용자가 선택을 확정하면 앱은 세션과 선택 식별자를 서버에 전달한다. 서버는 선택이 현재 장면의 유효한 선택인지 확인한다. 과거 화면에서 누른 선택이나 이미 처리한 요청을 현재 행동으로 잘못 적용하면 같은 행동이 반복 실행될 수 있으므로, 현재 선택의 버

전과 실행 상태를 함께 관리한다. 세션 단위의 동시 접근도 조정하여 서로 다른 요청이 같은 상태를 동시에 변경하지 않도록 한다.

행동에 결정적 효과가 연결되어 있으면 해당 실행기가 먼저 조건을 검사하고 결과를 계산한다. 이후 생성 단계에는 사용자가 고른 문구, 직전 장면의 맥락, 실행 결과와 현재 상태가 전달된다. 모델은 이 입력을 사용하여 행동의 수행과 후속 상황을 작성한다. 생성 후보가 검수를 통과하면 장면과 관련 상태를 확정하고 저장하며, 다음 선택을 준비한다.

실패 시에는 어떤 변경이 이미 확정되었는지 구분한다. 일반 행동 처리 중 아직 확정되지 않은 명단·인물·기억 변경은 이전 상태로 복구할 수 있어야 한다. 반면 이미 확정된 보스 전투의 승패나 보상은 서술 생성이 실패했다는 이유로 다시 계산해서는 안 된다. 따라서 모든 처리를 하나의 무조건적인 재시도에 넣지 않고, 실행 결과의 수명과 생성 작업의 수명을 구분하였다.



검수 실패 → 미확정 변경 복구 / 이미 확정된 전투 결과는 보존

그림 3. 선택 처리에서 검수와 상태 확정까지의 순서

이 구조의 사용 목적은 오류가 발생하지 않는다고 가정하는 것이 아니라, 발생했을 때 어느 결과를 유지해야 하는지 정하는 데 있다. 플레이어에게 보여준 결과, 서버가 저장한 상태, 다음 생성에 제공하는 입력이 같은 확정 지점을 가리키도록 관리한다. 후속 요청은 이 지점에서 다시 시작한다.

3.5. 결정적 실행이 제공하는 상태와 사건

전투·자원·아이템·이동·성장은 서사 생성이 따라야 할 결과를 제공한다. 전투 실행기는 전투원과 규칙 데이터를 받아 피해, 자원 소모, 승패와 보상을 계산한다. 아이템 처리는 소유 여부와 사용 조건을 검사하고, 이동은 허용된 목적지와 조건을 확인한다. 이 결과가 확정되면 모델은 그 사건의 표현과 인물의 반응을 작성한다.

생성 입력에는 현재 값과 완료 사건을 함께 제공한다. 전투 중 피해를 입었다는 사실과 보상 후 레벨업으로 체력이 가득 찬 상태는 동시에 참일 수 있다. 과거 피해만 주면 모델이 현재도 다친 것으로 묘사할 수 있고, 현재 체력만 주면 전투 경과를 임의로 채울 수 있다. 현재 상태는 다음 행동의 조건을, 완료 사건은 방금 벌어진 과정과 변화의 근거를 담당한다.

동작의 의도와 완료도 구분한다. 공격하려고 자세를 잡는 것은 서술할 수 있지만, 실제 명중이나 처치는 전투 결과가 있어야 확정할 수 있다. 구매를 고민하거나 다른 인물에게 물건을 부탁하는 대화는 가능하지만, 결제와 소유권 이전은 해당 정산이 수행되었을 때만 성립한다. 따라서 자연어에서 특정 동사가 등장했다는 이유로 정산을 실행하지 않는다.

이 설계는 모델에 규칙을 알려 주는 것에서 한 단계 더 나아가 상태의 변경 권한을 제한한다. 모델이 규칙을 위반한 문장을 반환하더라도 그 문장 자체가 HP·MP·소지금·장비 값을 쓰는 경로는 갖지 않는다. 다만 잘못된 문장이 검수를 통과하면 사용자는 틀린 상태를 인식할 수 있으므로, 상태 권한 분리와 서술 검증은 모두 필요하다.

3.6. 장면 생성과 동적 맥락

장면 생성은 현재 세계의 모든 정보를 입력하는 작업이 아니다. 지금의 선택을 수행하고 다음 상황으로 이어가기 위해 필요한 정보를 구성하는 작업이다. ContextBuilder는 현재 위치와 시각, 플레이어 상태, 직전 선택, 완료된 사건, 현재 인물과 기억을 결합한다. 새 게임의 오프닝과 이미 진행 중인 장면은 필요한 입력이 다르지만, 현재 위치와 상태의 근거를 사용하는 원칙은 공유한다.

최근 장면은 대화의 연결을 위해 구체적인 원문이 필요하다. 오래된 경험은 관련성 있는 요약을 제공하고, 현재 대화에 참여하는 인물은 해당 요청에서 사용할 수 있는 참조 목록으로 전달한다. 이때 과거에 만났다는 이유만으로 현재 같은 장소에 있다고 처리하지 않는다. 직전 선택에 참여한 인물이 다음 장면에도 필요하면 현재 선택의 맥락과 생존·위치 조건을 확인하여 연결한다.

장면의 출력은 표시 순서를 가진 sequence 배열로 구성한다. 각 항목은 서술이나 발화 등의 내용을 담으며, 발화에는 화자를 식별할 참조가 연결된다. 프로그램은 이를 실제 인물 정보와 연결하여 앱에 전달한다. 인물 참조를 사용하면 이름을 문자열로 비슷하게 작성했다는 이유로 다른 인물의 정보가 연결되는 문제를 줄일 수 있다. 존재하지 않는 참조나 현재 요청에서 허용되지 않은 대상을 반환하면 형식·참조 검사에서 거절한다.

장면은 직전 선택의 결과를 보여준 후 새로운 판단이 필요한 지점에서 끝나도록 구성한다. 행동을 준비하는 단계만 보여주고 같은 결정을 다시 묻는다면 플레이어는 선택의 효과를 느끼기 어렵다. 따라서 선택 수행, 관찰 가능한 반응, 달라진 상황을 하나의 인과적 흐름으로 작성하도록 한다. 장면 길이는 일정한 문장 수보다 이 흐름을 설명하는 데 필요한 분량을 기준으로 삼는다.

표 4. 장면 생성에 제공하는 맥락

입력 범주	포함 내용	필요한 이유
현재 세계	층·구역·시각·허용 환경	다른 장소의 규칙 혼입 방지
현재 상태	자원·소유·장착·명단	상태에 맞는 묘사와 판단
행동과 사건	직전 선택·정산 결과	선택 수행과 결과의 연속성
현재 인물	참조·프로필·접촉 맥락	화자와 등장인물의 동일성
최근 장면	서술과 대화의 원문	대화의 구체적인 연결
과거 경험	요약·관계·공유 사건	재등장과 장기 맥락의 유지


3.7. 선택 생성과 정산 연결

선택은 현재 장면에서 사용자가 실제로 답하거나 행동할 수 있는 내용이어야 한다. SceneEngine이 새로운 사건과 판단 상황을 만들면 ChoiceEngine은 그 상황에 대한 선택을 작성한다. 장면 생성기가 선택의 답안까지 미리 작성하고 선택 생성기가 같은 내용을 다시 판단하면 역할이 중복되므로, 장면은 현재 판단에 필요한 원문 구간을 전달하고 선택은 그 근거에서 작성하도록 나누었다.

일반 대화와 협상은 열린 자연어 선택으로 표현한다. 이 선택은 다음 장면의 의미를 바꾸지만 모두 즉각적인 정산 명령을 갖는 것은 아니다. 반면 정식 가입과 이동처럼 상태가 달라지는 동작은 표시 문구와 실행 정보를 연결해야 한다. “가입을 거절한다”는 문구에 가입 효과가 붙거나, 표시한 인물과 실제 가입 대상이 다르면 사용자의 의도와 결과가 어긋난다.

파티 가입에서는 현재 장면의 제안을 읽어 대상 인물을 확인한 뒤, 서버가 생존 여부와 현재 명단, 중복과 정원을 검사한다. 검사를 통과한 대상에 대해 수락 후 명단을 계산하

고 그 결과에서 수락 문구와 실행 내용을 함께 만든다. 선택 모델은 그 효과를 임의의 거절 문구에 결합하지 않고, 협상이나 보류 등 다른 자연어 대안을 작성한다.



다른 협상 · 질문 · 보류는 열린 자연어 선택으로 유지

그림 4. 파티 제안에서 수락 문구와 실제 명단을 연결하는 과정

층·구역 이동도 서버가 정한 대상과 실행 내용을 표시 문구에 연결한다. 생성 문장에 장소가 언급되었다는 이유만으로 이동을 실행하지 않는다. 실행 정보와 자연어 대안을 구분함으로써, 정확한 상태 변경이 필요한 부분을 보호하면서도 나머지 선택의 표현 범위는 유지한다. 선택이 확정된 이후에는 가입이나 이동의 완료 사실을 다음 장면에 전달하여 같은 행동을 다시 요구하지 않도록 한다.

3.8. 생성 검수와 상태 보호

생성 결과는 화면에 표시하기 전에 형식과 참조를 검사한다. 배열이나 필수 필드가 누락되면 후속 처리가 불가능하고, 인물 참조가 잘못되면 다른 사람의 대사나 관계가 연결될 수 있다. 이러한 오류는 자연어의 문학적 품질과 별개로 검사할 수 있다. 현재 요청에서 허용한 참조와 출력 구조를 대조하여 사용할 수 없는 후보를 거절한다.

형식이 올바른 문장도 사실과 충돌할 수 있다. 따라서 현재 상태와 완료된 사건을 근거로 생성 후보의 주장을 확인한다. 현재 생명력이 가득 찼는데 여전히 감소한 것으로 묘사하거나, 결제가 없는데 구매를 마쳤다고 말하는 경우가 그 대상이다. 현재 상태를 설명하는 문장에는 현재 값이, 동작이 완료되었다는 문장에는 해당 완료 사건이 근거가 되어야 한다.

의미 검수는 모델이 수행하므로 모든 오류를 결정적으로 검출하는 것은 아니다. 그러나 검수 결과를 적용하는 과정은 명확해야 한다. 필요한 판정이 누락되거나 거절된 후보가

있으면 해당 장면을 확정하지 않는다. 후보를 임의의 문장으로 고쳐 성공처럼 보이게 하는 대신, 기존 확정 상태를 유지하고 정해진 실패·복구 절차로 연결한다.

StateGuardrail과 상태 적용 경로는 모델이 보호되는 필드를 임의로 변경하지 못하도록 한다. 예를 들어 모델의 서술에서 아이템 획득을 주장하더라도 실제 획득 정산이 없다면 소유 목록을 그 문장에 맞추어 증가시키지 않는다. 반대로 정산이 실제로 이루어졌다면 그 결과를 다음 생성의 근거로 제공한다. 상태를 보호하는 기능과 서술의 오류를 찾아내는 기능은 함께 필요하다.

표 5. 오류 종류와 처리 경계

오류 종류	예시	처리
구조 오류	필수 출력이나 배열 형식 누락	응답 사용 중단과 제한된 구조 복구
참조 오류	현재 요청에 없는 인물 지정	연결을 거절하고 후보 미확정
완료 주장 오류	결제 없이 구매 완료 서술	근거 대조 후 후보 거절
상태 적용 오류	모델 결과로 보호 수치 변경 시도	해당 상태 변경 차단
서사 품질 문제	선택 반복·맥락 부족·부자연스러운 전개	기능 평가와 개선 대상으로 분석

이 경계에 따라 평가에서는 후보 거절의 집행 여부, 실제 상태의 보존, 최종 표시의 사실 정확성을 구분한다.

검수와 정보 추출은 하나의 구조화 응답에 함께 담기지만 역할은 구분된다. 파티 수락 사례의 응답은 표시 단위별 수용 판정, 선택 이행 판정, 인물 상호작용과 발화 관찰, 2인 파티 경험의 요약을 반환하였다. 이때 정식 파티 명단은 앞선 실행 단계가 계산하여 생성·검수에 제공한 상태이며, 추출된 요약이 명단을 새로 정산하는 것은 아니다. 일반 행동의 최종 확정·저장은 후보 검수를 통과한 뒤 이루어진다.

표 6. 파티 수락에서의 추출 정보와 확정 권한

정보	응답에서 확인한 내용	확정과 사용의 경계
후보의 판정	표시 6단위 수용, 선택 이행 확인	서버가 판정의 유효성과 누락 여부를 확인하고 후보 확정에 사용
경험과 인물 정보	파티 수락의 상호작용·발화 관찰, 경험 요약·중요도	인물·기억 갱신 후보로 사용하며 체력·골드·정식 명단의 정산을 대체하지 않음
정식 파티 상태	엘비라·리디아의 2인 명단	선택에 연결된 실행 단계가 계산하여 생성·검수에 근거로 공급하고, 후보 검수 통과 후 최종 확정·저장

3.8.1. 의미 검수의 입력과 판정 단위

검수 요청에는 생성 후보의 표시 단위마다 부여한 식별자와 원문, 현재 상태, 이번 행동의 완료 사건, 해당 장면의 위치·활동 범위가 들어간다. 상태 근거는 현재 HP·MP·소지금·장비·파티와 같은 값이며, 완료 근거는 이번 행동에서 실제로 수행된 구매·가입·이동·전투 결과이다. 선택 원문은 사용자의 의도이지 완료 사건의 증거가 아니다.

LLM은 각 식별자에 admit 또는 reject를 반환한다. 현재 사실과 일치하거나 상태 완료를 보증하지 않는 계획·질문·시도는 수용할 수 있다. 현재 사실과 충돌하거나 완료를 직접 뒷받침할 근거가 없는 주장은 거절 대상이다. 하나의 표시 단위에 여러 사실이 있으면 그중 검수 대상 사실 하나가 어긋나도 해당 단위를 거절한다. 예를 들어 '물약을 사자고 제안했다'와 '물약을 구매했다'는 같은 물약을 언급하지만 서로 다른 근거를 요구한다.

서버는 의미 판정의 결과뿐 아니라 판정 목록 자체도 검사한다. 요청의 모든 식별자가 정확히 한 번 포함되어야 하며, 누락·중복·알 수 없는 식별자가 있으면 사용할 수 없는 응답으로 처리한다. 유효한 판정 중 하나라도 거절이면 후보 장면을 확정하지 않는다. 장면의 장소·활동 범위와 선택 이행 여부도 별도 판정으로 연결하며, 형식 검사만 통과한 응답을 의미 검증 성공으로 간주하지 않는다.

3.8.2. 확정과 복구의 처리 경계

일반 행동의 처리 순서는 이전 확정 상태 확보, 현재 선택의 유효성 검사, 결정적 동작 수행, 새 상태와 사건을 이용한 생성, 후보 검수, 상태·장면·기억의 반영 및 저장이다. 중간에 후보가 거절되면 아직 확정되지 않은 변경을 복원한다. 이때 인물이나 관계·기억의

일부만 남지 않도록 관련 상태를 함께 복구한다. 재생성의 성공 여부와 자원 정산의 중복 여부를 같은 재시도 횟수로 관리하지 않는다.

오프닝에는 직전 선택의 완료 사건이 없으며 시작 상태가 기준이다. 일반 진행에는 선택과 그에 따른 확정 사실이 추가된다. 이미 결과를 확정된 전투 작업은 후속 서술이 실패해도 그 승패와 보상을 다시 계산하지 않는다. 이 구조는 애플리케이션의 확정·복구 계약이며 모든 외부 효과가 하나의 데이터베이스 트랜잭션으로 묶인다는 뜻은 아니다.

실패를 복구했더라도 다음 행동이 반드시 진행되는 것은 아니다. 복구 뒤에도 입력 참조 오류나 생성 실패가 반복되면 세션은 중단될 수 있다. 따라서 평가에서는 '이전 값이 유지됨'과 '플레이가 이어짐'을 별도로 기록한다.


3.9. 4계층 기억의 저장과 활용

기억 시스템은 감각 기억, 작업 기억, 일화 기억, 의미 기억의 네 계층으로 구성하였다. 감각 기억은 최근 장면의 원문을 보관하여 대화와 행동의 세부 연결을 유지한다. 작업 기억은 가까운 장면의 요약과 중요도를 관리한다. 일화 기억은 이후에도 참조할 중요한 경험을, 의미 기억은 장기간 사용할 정보를 보관한다. 각 계층은 같은 문장을 네 번 복제하기 위한 것이 아니라 정보의 구체성, 지속 기간, 검색 목적을 나누기 위한 것이다.

감각 기억의 원문은 최근 장면을 이어 쓰는 데 사용한다. 예를 들어 상대가 방금 어떤 질문을 했는지, 주인공이 어떤 말에 답하려는지와 같은 정보는 압축된 요약만으로 복원하기 어렵다. 따라서 현재 장면에 가까운 내용은 구체적으로 유지한다. 반면 오래된 모든 대사를 계속 제공하면 문맥이 길어지고 과거 표현이 반복될 수 있으므로, 장기적인 입력에는 요약을 사용한다.

표 7. 기억 계층별 저장 내용과 역할

계층	저장하는 내용	주요 사용 목적
감각 기억	최근 장면의 서술과 대화 원문	직전 행동과 대화의 구체적 연결
작업 기억	가까운 장면의 요약과 중요도	현재 전개에 초점 유지
일화 기억	중요한 사건과 출처 정보	과거 경험의 회상과 관계 연결
의미 기억	지속적으로 참조할 정보와 근거	장기적인 맥락 제공



최근 원문은 구체성을 유지하고 장기 계층은 요약과 출처를 사용

그림 5. 장면 원문과 요약을 구분한 기억 저장 구조

최근 원문은 감각 기억에 보관하고, 작업 기억에는 요약과 출처를 저장한다. 감각 기억의 원문을 그대로 장기 계층으로 승격하지 않으므로 오래된 대사가 여러 계층에서 반복 공급되는 경로를 제한한다. 이 설계는 직전 대화의 세부를 유지하면서 장기 입력에는 사건의 핵심을 제공하기 위한 것이다.

요약도 사실 오류에서 자유롭지는 않다. 원래 장면이 잘못된 파티 구성을 서술했다면 그 내용을 요약한 기억도 잘못될 수 있다. 따라서 기억이 다음 입력에 전달되었다는 사실과 내용이 정확하다는 사실을 구분하여 평가한다. 기억 계층의 존재만으로 일관성이 보장되는 것이 아니라, 저장 전의 검수와 현재 상태의 명시적인 제공이 함께 필요하다.

3.9.1. 저장과 승격의 실제 조건

작업 기억의 요약과 중요도는 장면 처리의 추출 응답에서 함께 반환된다. 중요도는 0~1 범위의 모델 판정이며 사실의 정확도를 뜻하는 확률은 아니다. 프로그램이 그 값과 저장 조건을 사용해 보존 여부를 결정한다. 예를 들어 리디아의 파티 수락 장면에서는 파티장과 2인 결성 내용을 담은 요약에 중요도 0.6이 반환되었다.

작업 기억은 최대 7개 슬롯을 유지하고 장면 순서를 우선하여 오래된 항목을 밀어낸다. 완료 장면에서 중요도 0.25 이상인 미승격 슬롯을 일화 기억으로 옮기며, 원래 장면과 인물의 출처를 함께 저장한다. 승격 여부를 기록하므로 같은 슬롯이 장면 완료마다 중복

추가되지 않는다. 최근 원문이 작업·일화 계층으로 그대로 승격되는 경로 대신 요약을 장기 기억의 진입점으로 사용한다.

완료된 플레이 장면 10개 단위의 체크포인트에서는 기준 중요도에 0.95의 경과 체크포인트 수 제곱을 곱해 시간에 따른 중요도를 계산한다. 매번 직전 감쇠 값에 중복 감쇠를 적용하지 않고 기준 점수와 경과량에서 계산한다. 조정 후 중요도 0.65 이상이고 아직 의미 기억으로 옮기지 않은 경험은 같은 내용과 원래 기억의 식별자를 의미 계층에 연결한다. 이 경로는 개별 경험을 장기 보존하는 것이며, 사례 하나에서 세계 전체의 새로운 규칙을 자동 도출했다는 뜻이 아니다.

3.9.2. 네 계층을 사용하는 이유와 대안

최근 원문만 유지하는 방식은 대화의 세부를 보존하기 쉽지만 오래된 경험이 입력에서 밀려난다. 원문에 단일 요약을 붙이는 방식은 구조가 간단하지만 단기 초점과 오래 유지할 사건, 지속적인 지식을 같은 요약에 함께 관리해야 한다. 본 구현은 이 세 보존 목적을 분리하여 최신성에 따른 교체와 중요도에 따른 보존을 다르게 적용한다.

대신 계층 간 중복, 요약의 사실성, 승격 시점과 예산을 함께 관리해야 하는 부담이 생긴다. 네 계층은 이러한 요구를 구현한 설계 선택이며, 계층 수를 바꾸어 우열을 측정한 결과는 없다. 뒤의 FULL/M0 비교도 장기 기억을 입력에 제공하는 효과를 보는 실험으로, 각 계층의 개별 기여나 네 계층의 최적성을 입증하지 않는다.

3.10. 기억 입력 예산과 중복 관리

모든 기억을 동시에 입력하면 중요한 최근 맥락이 오래된 정보에 묻힐 수 있다. TokenBudgetAllocator는 전체 기억 입력 예산을 계층별로 나누어 각 계층에서 사용할 내용을 선택한다. 현재 기본 비율은 감각 60%, 작업 18%, 일화 13%, 의미 4%, 예비 5%이다.

실제 배분은 호출 경로에 따라 달라진다. 장면 생성에 최근 원문을 별도 항목으로 이미 제공했다면 기억 묶음에서 감각 기억을 다시 넣지 않는다. 해당 예산과 비어 있는 계층의 여유분은 작업·일화 기억에 배분한다. 이로써 같은 원문을 여러 곳에서 반복 제공하는 문제와, 사용할 내용이 없는 계층 때문에 입력 공간을 낭비하는 문제를 함께 다룬다.

내용의 중복도 관리한다. 현재 인물과의 공유 경험을 별도 구간에 넣었다면 과거 사건 목록에서 같은 요약을 다시 넣지 않는다. 계층 간에는 상위에서 사용한 내용을 기록하고

하위 계층에서 같은 내용을 중복하여 선택하지 않도록 한다. 동일 문장을 여러 번 넣는 것이 근거의 수를 늘리는 것처럼 작동하지 않게 하기 위한 설계이다.



최근 원문 별도 공급 시 해당 몫을 작업·일화 기억에 재배분

그림 6. 기억 검색과 입력 예산의 구성

이 구조는 기억의 양을 줄이는 것만을 목적으로 하지 않는다. 현재 대화를 이해하는 데 필요한 최근 정보는 유지하고, 장기 경험은 관련성 있는 형태로 제공하는 것이 목적이다. 따라서 단순한 전체 요약 하나나 고정된 마지막 몇 줄만 사용하는 방식과 달리, 현재 장면과 과거 경험의 역할을 함께 고려한다. 기억 품질의 평가는 실제로 필요한 경험이 전달되는지와 그 경험의 사실성이 유지되는지를 함께 확인하도록 구성하였다.

기억 컨텍스트의 기본 예산은 3,500 추정 토큰이다. 이 예산은 시스템 규칙·현재 상태·출력 등 전체 요청을 포함한 모델 문맥 한도가 아니라 기억 블록에 사용하는 한도이다. 코드에서는 문자열 길이에 따른 토큰 추정치를 사용하므로 실제 공급자의 토큰 사용량과 완전히 같지는 않다.

검색은 의미 기억, 일화 기억, 작업 기억, 최근 원문 순으로 구성한다. 의미 기억은 신뢰도 순으로, 일화 기억은 경과가 반영된 중요도에 장면 순서와 체크포인트 요약의 가산점을 더한 순으로 선택한다. 작업 기억은 최근 장면을 우선한다. 각 항목이 남은 예산 안에 들어갈 때 포함하고, 상위 블록이나 공유 경험에 이미 포함된 동일 내용은 제외한다. 따라서 모든 기억이 매번 입력되는 것은 아니다.

예비 몫과 비어 있는 의미 계층의 몫, 별도 원문 공급으로 제외한 감각 계층의 몫은 작업·일화 기억의 비율에 따라 재배분한다. 이 방법은 단순한 고정 비율 절단보다 빈 계층으로 인한 낭비를 줄이지만, 최적 예산 배분을 실험으로 구한 것은 아니다.

3.11. 관계 하이퍼그래프와 인물의 지속성

관계 그래프는 인물, 장소, 집단, 사건 등의 연결을 저장한다. 일반적인 두 노드 간 관계 외에도 여러 노드가 하나의 경험에 참여한 관계를 표현할 수 있도록 하이퍼그래프를 구현하였다. 각 노드와 간선을 식별자로 관리하고, 노드가 참여한 간선을 빠르게 조회할 수 있는 인접 인덱스를 둔다. 주변 관계를 탐색할 때에는 간선 종류와 탐색 거리를 기준으로 범위를 제한할 수 있다.




그림 7. 여러 인물과 공동 경험을 연결하는 하이퍼그래프 예시

현재 인물을 위한 맥락은 관계 그래프의 전체 내용을 그대로 출력하지 않고 필요한 항목을 조회하여 구성한다. 인물의 최근 상호작용과 관계, 함께 겪은 사건의 요약을 별도로 제공한다. 공유 경험은 사건 요약을 사용하고, 이미 다른 기억 구간에 포함된 내용은 다시 넣지 않는다. 동일한 두 인물 사이에도 친분 간선과 사건 참여 간선이 함께 존재할 수 있으므로, 필요한 관계 종류를 구분하여 읽는다.

인물의 이름과 실제 정체성도 분리하여 관리한다. 모델이 작성하는 대사에는 현재 요청에서 허용된 참조를 사용하고, 프로그램이 그 참조를 인물의 이름과 프로필에 연결한다. 처음 등장한 인물과 이미 만난 인물이 같은 숫자 순번을 사용하더라도 서로 다른 참조 범위를 갖도록 한다. 인물의 별칭이나 문장상의 호칭이 달라져도 실제로 누구를 가리키는지 유지하기 위한 장치이다.

현재 장면에 등장하는 인물과 장기 관계에 등록된 인물은 같은 집합이 아니다. 과거에 만났지만 현재 다른 위치에 있는 인물은 회상이나 소문의 대상일 수는 있어도 자동으로 현재 대화의 화자가 되지 않는다. 반대로 직전 선택의 대화 상대는 다음 장면에도 필요

할 수 있으므로, 선택 직전의 인물 맥락을 현재 선택과 함께 전달한다. 이러한 현재성의 관리가 장기 기억과 즉시 대화의 연속성을 연결한다.

3.11.1. 공유 경험의 자료구조와 검색

하이퍼그래프의 노드는 인물·장소·집단·사건을 식별하고, 간선은 관련 노드의 집합과 관계 유형, 중요도, 경험의 근거를 연결한다. 공동 참여, 목적, 원인과 같은 관계를 구분하므로 같은 인물이 사건에 등장하더라도 어떤 관계로 연결되었는지 유지할 수 있다. 인물별 인접 간선 목록을 두어 전체 그래프를 매번 순회하지 않고 관련 연결부터 검색한다.

두 인물의 공유 경험을 조회할 때는 두 인물 중 연결 간선이 적은 쪽에서 시작한다. 그 간선들 중 공동 참여·목적·원인 유형에 해당하고 다른 인물도 포함된 항목을 고른 다음 중요도 순으로 정렬한다. 검색한 경험의 요약은 생성 입력에 제공하며, 같은 요약이 일화 기억에서도 선택되면 내용 중복을 제거한다. 과거 공동 경험이 있다는 사실만으로 현재 같은 장소에 있다고 판단하지는 않는다.

예를 들어 인물 A·B·C가 한 장소에서 공동 사건을 경험했다면 하나의 사건 관계에 참여자를 묶어 둘 수 있다. A와 B의 공유 경험을 찾았을 때 C도 그 사건의 참여자라는 맥락을 유지할 수 있다. 이 예는 자료구조의 설명이며 특정 실행의 성능 측정값은 아니다.

일반 그래프에서 사건을 별도 노드로 두고 참여자와 연결해도 같은 정보를 표현할 수 있다. 본 구현은 다자 관계를 간선 단위로 관리하는 구조를 사용하여 관계의 구성원과 속성을 함께 조회한다. 대신 간선 구성원·인덱스·저장 복원의 일관성을 관리해야 한다. 일반 그래프보다 표현력이나 검색 성능이 실측으로 우수하다고 결론짓지 않는다.

3.11.2. AI 플레이어와 세계 변화의 입력 범위

현재 인물의 프로필과 관계, 직전 선택의 참여자, 현재 위치와 세계 진행도를 장면 맥락에 연결한다. 직전 선택에 필요한 인물은 같은 장소에 있고 살아 있는지 확인하여 다음 요청에서 식별 가능하게 한다. 과거에 만난 인물, 현재 장면에 등장 가능한 인물, 세계에 존재하는 인물 전체는 서로 다른 집합이다.

세계의 변화도 전달 방식에 따라 구분한다. 배경 정합성을 위한 참고 정보는 주인공이 이미 관찰한 사실로 바꾸지 않으며, 시스템 공지·다른 인물의 발언·소문·직접 관찰 가능한 환경 변화를 각각 구분한다. 예를 들어 다른 인물이 전한 경험은 그 인물의 말로 유지하고 시스템 전체의 확정 규칙으로 승격하지 않는다. 현재 장면에 필요한 맥락만 공급함으로써 배경 정보와 인물의 지식을 구분한다.

3.12. Flutter 화면과 정보 표현

공식 클라이언트는 Flutter로 구현하였다. 핵심 화면은 장면을 읽고 선택하는 게임 화면이며, 캐릭터 정보와 아이템, 장비, 인물 관계, 시설 등의 기능을 함께 제공한다. 서버에서 받은 장면과 상태를 표시하고 사용자의 조작을 요청으로 전달한다. 클라이언트가 별도의 전투 결과나 자원 수치를 계산하지 않도록 서버 상태를 기준으로 갱신한다.

게임 화면은 서술, 인물 정보, 대화, 선택을 하나의 열에서 읽는 구조이다. 장면이 길어지더라도 현재 사건의 순서가 유지되도록 내용을 누적하여 보여준다. 화자의 이름과 프로필 정보는 발화와 연결하고, 일반 서술과 인물의 말은 시각적으로 구분한다. 캐릭터 얼굴 자산이 제공되는 경우 인물 식별을 돕도록 사용하며, 이미지가 없는 경우에도 본문을 읽는 흐름이 유지되도록 구성하였다.

그림 8은 리디아가 엘비라의 파티 제안을 수락하는 선택과 다음 장면의 반응을 보여준다. 선택 카드에는 수락 후 인원이 표시되고, 다음 장면에서는 수락 발언·결성 서술·엘비라의 감사 인사가 이어진다. 2026년 9월 10일 실행의 장면 데이터를 Flutter 화면에 표시한 것으로, 같은 행동의 서버 상태와 함께 해석한다.



그림 8. 파티 수락 선택과 다음 장면의 결성 및 반응

표 8. 파티 수락 사례의 입력과 결과

관측 지점	확인 결과
선택 전	정식 파티 없음
확정 명단	파티장 엘비라, 구성원 리디아·엘비라
검수와 기억	6개 표시 단위 수용, 2인 결성 요약 추출(중요도 0.6)

선택은 읽는 과정과 확정하는 과정을 구분한다. 사용자가 긴 문장을 읽는 중에 의도하지 않은 행동을 실행하지 않도록 확정 동작을 별도로 관리한다. 생성과 행동 처리가 진행 중이면 중복 조작을 제한하고, 키보드 입력이 반복되더라도 같은 선택 요청이 연속으로 전송되지 않도록 한다. 현재 장면의 선택 데이터 자체는 표시를 위해 문장을 줄이거나 재작성하지 않고 유지한다.

장문 텍스트는 화면 폭과 글꼴, 언어, 글자 배율을 고려하여 줄바꿈한다. 화면의 줄바꿈을 조정하더라도 복사와 접근성 정보에는 원래 문장을 유지하도록 구성하였다. 대화의 화자와 발화가 중복해서 읽히지 않도록 의미 정보를 연결하고, 이미지 로딩 실패가 본문 자체의 누락으로 이어지지 않게 처리한다. 이와 같은 구현은 텍스트가 주요 콘텐츠인 게임의 읽기 경험을 위한 것이다.

시스템 화면에서 아이템을 확인하거나 시설 조작을 하더라도 현재 주 장면의 선택은 유지한다. 단순 목록 조화가 이야기를 진행시키거나, 화면을 닫았다는 이유로 숨은 행동이 자동 선택되지 않도록 하였다. 사용자는 필요한 시스템 정보를 확인한 뒤 같은 판단 지점으로 돌아온다. 이 방식은 이야기의 선택과 정확한 항목 조작을 하나의 모바일 경험 안에서 연결한다.

자연어 선택은 파티 가입처럼 공식 명단이 바뀌는 행동 외에도 상황에 대한 대응을 표현한다. 그림 9에서 시온은 정면의 슬라임과 후방 경쟁 파티 사이에서 공격·방어·관찰 중 하나를 선택한다. 방어 진형을 굳히는 선택 뒤에는 메탈이 개입할 틈이 없다고 판단하여 철수를 지시하고, 경쟁 파티가 물러나는 반응이 이어진다. 플레이어는 그 결과를 읽은 뒤 남은 슬라임에 어떻게 대응할지 판단한다.





그림 9. 방어 진형의 선택과 경쟁 파티 철수의 후속 반응

이 사례의 캐릭터 자원과 공식 파티 상태는 전후 동일하다. 선택에 따른 변화는 상대의 철수와 후속 판단이라는 서사적 결과로 나타났다. 수치 보상이나 명단 변경을 수반하지 않는 선택도 인물의 행동과 상황 변화로 이어질 수 있음을 보여준다.

3.13. 서버 통신과 비동기 처리

앱과 서버의 일반 요청은 REST API로 전달한다. 세션 시작과 재개, 현재 상태 조회, 장비와 아이템 조작, 인물 관계 조회 등은 요청에 대응하는 구조화된 결과를 받는다. 장면 처리처럼 시간이 걸리는 작업은 SSE를 통해 진행 상태와 결과를 전달한다. 사용자가 기다리는 동안 앱은 현재 처리 단계를 보여주고, 완료 결과를 받으면 장면과 상태를 갱신한다.

비동기 요청에서는 응답이 도착할 때 사용자가 여전히 같은 세션을 보고 있는지 확인해야 한다. 이전 세션의 늦은 응답이 현재 화면을 덮어쓰면 다른 캐릭터의 상태가 표시될 수 있다. 따라서 요청한 세션의 결과를 해당 세션에만 적용하도록 하고, 여러 작업이 겹치면 모든 작업이 끝날 때까지 처리 중 상태를 유지한다. 단순 조회와 실제 변경 요청의 상호작용도 구분한다.



앱은 서버가 확인한 상태를 표시하고 게임 수치를 다시 계산하지 않음

그림 10. Flutter 요청과 서버 처리 결과의 전달

서버는 장면 생성과 선택 준비의 실행 상태를 관리한다. 같은 선택 생성 작업을 여러 요청이 기다릴 수 있어도 실제 생성이 불필요하게 중복되지 않도록 작업을 식별한다. 실패 복구에서도 논리적인 작업과 실제 전송 횟수를 구분한다. 구조 복구는 정해진 범위에서 수행하고, 게임 정산을 다시 실행하는 수단으로 사용하지 않는다.


서버가 통과한 결과만 앱에 전달한다는 원칙은 통신 형식과 함께 유지된다. 모델 응답이 도착했다는 사실과 플레이어에게 보여줄 장면이 확정되었다는 사실은 다르다. 앱은 검수와 상태 처리가 끝난 응답을 소비한다. 이렇게 서버의 확정 시점과 화면 갱신 시점을 연결하여, 화면에는 성공처럼 보이지만 저장은 실패한 상태가 되는 문제를 줄이도록 설계하였다.

3.14. 자동 저장과 실패 복구

세션은 현재 캐릭터 상태뿐 아니라 장면과 선택, 기억과 관계 등 다음 플레이를 이어가는 데 필요한 정보를 포함한다. 자동 저장은 이 정보들이 같은 진행 지점을 가리키도록 해야 한다. 자원 값만 복원되고 선택이 과거 장면의 것으로 남으면 재개 직후 잘못된 행동을 수행할 수 있다. 따라서 장면의 식별 정보와 선택의 유효성도 함께 관리한다.

재개 요청에서는 저장된 세션을 불러온 뒤 진행 중이던 작업의 상태를 확인하고 현재 장면의 응답을 구성한다. 생존한 캐릭터는 현재 선택으로 이어가고, 사망한 세션은 선택을 비활성화하여 종료 결과를 보여준다. 저장 호환성 처리는 기존 세션을 읽기 위한 것이며, 과거 플레이어의 결과를 임의로 새 규칙에 맞추어 다시 생성하지 않는다.

행동 중 오류가 발생하면 아직 확정되지 않은 변경을 복구한다. 파티 명단이 변경된 뒤 장면 검수가 실패했다면 명단만 남아서는 안 되고, 새 인물 등록이나 기억 변경도 같은 경계에서 처리해야 한다. 관계 그래프는 노드와 간선의 스냅샷을 저장하고 복원 시 연결 인덱스를 다시 구성할 수 있도록 구현하였다. 이로써 객체의 일부만 이전 상태로 돌아가는 문제를 피하도록 한다.



이미 확정된 전투·보상은 서술 실패를 이유로 다시 계산하지 않음

그림 11. 확정 상태를 기준으로 한 저장과 복구

이미 확정된 결과가 있는 작업은 별도 원칙을 적용한다. 예를 들어 보스 전투의 결과가 저장된 이후에는 같은 전투와 보상을 다시 계산하지 않는다. 후속 서술의 실패는 그 결과를 유지한 상태에서 처리한다. 일반적인 미확정 행동의 rollback과 이미 확정된 전투 결과의 보존을 구분하여, 복구가 새로운 게임 결과를 만드는 일이 없도록 구성하였다.

저장·복구는 저장 상태를 분리하여 불러오는 검사와 공개 재개 응답의 필드 비교로 평가하였다. 비교 결과와 운영 환경별 검증 범위는 제4장에 제시한다.

3.15. 파티 수락의 전체 처리 사례

파티 수락은 본 시스템의 통합 성과를 보여주는 대표 사례이다. 플레이어가 읽은 제안과 선택의 효과가 실제 명단으로 이어지고, 그 결과가 다음 대화와 기억 추출에도 반영되어야 한다. 그림 8과 함께 제시한 입력·결과 비교는 동일한 수락 행동을 화면과 서버 상태에서 확인한 것이다. 여기서는 그 결과가 만들어지는 처리 경로를 설명한다.

리디아의 두 번째 장면에서 엘비라는 주변 시설과 동선을 함께 확인하자고 제안하였다. 화면에는 ‘엘비라의 파티 제안을 수락한다 · 수락 후 2인 (리디아, 엘비라)’, 혼자 살피겠다는 거절, 동선만 확인하는 조건부 질문의 세 선택이 제시되었다. 첫 번째 선택을 수행하기 전 정식 파티 상태는 비어 있었다.

서버가 제공한 수락 선택은 가입 대상과 수락 후 명단을 포함한다. 선택 요청 이후 장면 생성에는 사용자가 수락했다는 행동과 현재 턴에 확정된 파티 사실을 전달한다. 다음 장면은 리디아의 동의 발언에서 시작하며, 엘비라가 파티장이 된 2인 파티의 결성을 서술하고 ‘수락해 주셔서 고마워요, 리디아 씨’라는 반응으로 이어졌다.

해당 후보의 검수 응답은 여섯 표시 단위 모두에 수용 판정을 반환했고, 선택 이행 판정은 수락 발언과 결성 서술을 근거로 이행되었다고 판정했다. API 응답의 실제 파티장은 엘비라, 구성원은 리디아와 엘비라였다. 즉 수락 문구, 후속 장면, 반환된 명단이 같은 가입 결과를 가리켰다. 기억 추출에도 엘비라가 파티장인 2인 파티가 성립했다는 요약과 중요도 0.6이 반환되었다.

이 처리에서 플레이어가 선택한 수락의 의미는 다음 장면의 동의와 감사 인사로 이어졌고, 정식 파티 상태는 2인 명단으로 반영되었다. 서버가 정산할 사실을 확정하면서도 인물의 반응은 자연어로 표현할 수 있음을 한 번의 정상 처리에서 확인하였다. 선택·실행·장면·기억 추출을 연결한 구현의 의의가 여기에 있다. 반복 동작과 저장·재개의 확인 결과는 제4장에서 별도로 제시한다.

3.16. 설계 대안과 통합 과정의 주요 결정

본 과제에서는 생성 모델의 표현 능력을 유지하면서 오류가 실제 상태와 이후 장면으로 전달되는 경계를 제어하는 데 설계의 초점을 두었다. 이를 위해 규칙 실행, 경험 공급, 후보 검수와 확정을 분리하고 각 단계가 주고받는 자료를 명시하였다. 단일 응답의 정확

성만 확인하는 구조에서 선택 이후의 상태·기억·후속 장면을 함께 확인하는 구조로 통합 범위를 확장하였다.

상태 처리에서는 자연어에서 결과를 추측하여 수치를 바꾸는 방식과, 모든 행동을 고정 메뉴로 제한하는 방식을 모두 피하였다. HP·소유물·정식 명단처럼 정답이 있는 값은 프로그램이 관리하고, 대화·협상·인물의 반응은 생성 모델이 작성하도록 하였다. 파티 수락은 이 경계의 대표 사례로, 서버가 계산한 명단에서 표시 문구와 실행 정보를 함께 구성한다. 제3.15절의 수락 사례는 이 결정이 실제 선택과 후속 장면에 적용된 결과이다.

기억 처리에서는 최근 대화의 원문과 장기 경험의 요약을 분리하였다. 원문을 계속 누적하면 구체성은 남지만 입력이 길어지고 과거 표현이 반복될 수 있다. 모든 내용을 요약하면 직전 대화의 세부를 잃을 수 있다. 이에 최근 원문을 별도로 유지하고, 중요도·출처를 갖춘 요약을 장기 계층에 보존하며, 현재 인물과 연결된 경험은 관계 검색으로 공급하도록 구성하였다.

검수와 저장의 통합에서는 후보 생성 완료를 게임 상태 확정으로 취급하지 않았다. 후보의 구조·참조·의미 판정을 확인한 뒤 상태와 장면을 적용하고, 실패 시 미확정 변경을 복구한다. 이미 확정된 전투·보상은 다시 계산하지 않는다. 이러한 결정은 모델 응답의 성공 여부와 게임 결과의 중복·손상을 별도로 관리하게 하며, 정상 처리와 후보 거절 모두를 관측할 수 있는 평가 기반이 된다.

아래 비교는 구현 요구에 대한 설계 대안의 비교이다. 각 방식의 비용이나 생성 품질을 동일 조건에서 실측한 순위가 아니라, 본 과제에서 선택한 책임과 관리 단위를 설명한다.

표 9. 핵심 요구에 따른 설계 대안과 선택

설계 요구	비교한 대안	본 과제의 선택과 이유	관리해야 하는 부담
자유로운 선택과 정확한 정산	자연어에서 상태를 추정하거나 고정 명령만 제공	표현은 자연어로 두고 정산 대상·효과를 실행 정보에 연결	선택·실행·후속 장면이 같은 사건을 가리켜야 함
직전 대화와 오래된 경험 유지	최근 원문만 유지하거나 단일 요약 사용	최근 원문과 보존 목적별 기억 계층을 분리	요약의 사실성·승격·예산·중복 관리
여러 인물의 공동 경험 검색	문장 검색 또는 사건 노드를 둔 일반 그래프	참여자나 사건 속성을 하나의 관계로 관리하고 현재 인물의 경험 조회	간선 구성원·인접 인덱스·저장 복원 관리
오류 후보와 게임 결과의 분리	생성 직후 적용하거나 검수 판정만 기록	판정 결과를 장면·기억·상태의 확정과 복구에 연결	미확정 변경과 이미 확정된 결과의 경계 관리

이 설계의 가치는 각 기능을 함께 사용하는 과정에서 드러난다. 파티 수락에서는 정확한 명단과 자연스러운 반응이 같은 행동에서 생성되고, 관계 검색은 그 경험을 현재 인물의 맥락으로 다시 공급한다. 후보가 거절되면 그 결과를 표시와 상태 적용에도 집행한다. 따라서 구현의 핵심은 기억이나 검출기를 개별적으로 호출하는 것에 더해, 각 단계의 결과가 다음 단계에서 갖는 권한과 의미를 일치시킨 데 있다.

3.17. 개발 단계와 범위의 변화

개발은 규칙과 서술의 책임 분리, 기억·관계 구조의 연결, Flutter와 API 통합, 연속 플레이에서 발견한 정합성 문제의 개선으로 진행하였다. 초기에는 단일 응답의 구조를 확인하는 데 초점을 두었으나, 이후에는 선택의 의미가 실행 결과와 다음 장면에 전달되는지, 오류가 기억을 통해 반복되는지까지 확인 범위를 넓혔다.

화면 구성은 Flutter 앱을 중심으로 정리하였으며, 장면마다 배경 이미지를 생성하는 방식은 최종 핵심 범위에서 제외하였다. 인물의 얼굴과 표정은 대화의 표현을 보조하지만, 본 과제의 주된 검증 대상은 텍스트의 사실 일관성과 상태 보호이다. 이미지 생성 품질이나 게임 전체 콘텐츠의 완성도는 환각 통제 성능과 별도의 문제이다.

최종 평가에서는 실제 진행, 정산 상태, 기억 전달, 검출기 성능을 구분하였다. 초기 계획에서 제시한 모든 비교·사용자 평가가 완료된 것은 아니며, 수행한 평가와 남은 과제는 결과 장에서 구체적으로 구분한다.

3.17.1. 개발 일정과 주요 산출물

졸업과제의 수행 일정은 착수 단계의 목표 정리, 중간 단계의 통합 구현, 자문과 평가, 최종 사례 분석의 순서로 진행하였다. 다음 표는 각 시점에 정리하거나 확인한 주요 산출물을 나타낸다.

표 10. 졸업과제 수행 일정과 주요 산출물

시점	주요 수행 내용	산출물과 확인 범위
2026년 5월 15일	착수 목표와 설계 범위 정리	책임 분리와 다계층 검증의 목표, 구현 및 평가 계획
2026년 7월 16일	중간 구현과 연속 플레이 결과 정리	Flutter·서버 통합, 30장면의 오류 전파 사례, 최종 평가 계획
2026년 8월 6일	산업체 멘토 자문	핵심 처리 흐름과 전후 사례, 동일 조건 정량 비교의 보완 방향
2026년 8월 말	기억 입력과 검출기 평가 자료 구성	FULL/M0 기억 비교와 490개 표시 단위의 검출 성능 평가
2026년 9월 8~10일	선택·상태·기억의 통합 평가	선정 8세션의 기능별 분석, 저장·재개 대조, 파티 수락 사례
2026년 9월 11~13일	최종 결과와 제출 자료 정리	핵심 설계·실험 결과·수행 범위를 종합한 최종보고서

중간 단계의 장기 플레이·이미지·통합 복구 평가 계획은 실제 수행 범위에 맞추어 조정하였다. 완료한 평가와 추가 검증 항목은 제4장의 주요 평가 계획과 최종 수행 범위에 구분하여 제시한다.

3.18. 구성원별 역할과 담당 범위

본 과제의 역할 분담은 코어 아키텍처와 게임 상태 관리, 모바일 클라이언트와 서버 통신, AI 생성과 일관성 검증으로 구성하였다. 구성원별 담당 범위는 다음과 같다.

3.18.1. 박찬오 — 코어 아키텍처와 게임 시스템

박찬오(202155557)의 담당 범위는 기존 코어 아키텍처와 결정론적 게임 시스템의 유지·고도화 및 최종 통합이다. 게임 루프, 상태 전이, 전투 판정, 저장·세션 구조와 DataBridge, StateGuardrail, Memory/Graph 계층의 통합을 담당한다. 서버 API의 상태 변경 경계, 데이터 무결성, 밸런스 및 팀원 구현분의 통합 리뷰를 포함한다. 본 보고서의 규칙 데이터와 상태 모델, 행동 처리와 상태 확정, 기억·관계 구조, 저장·복구에 해당하는 영역이다.

3.18.2. 김동현 — 모바일 클라이언트와 서버 통신

김동현(202155524)의 담당 범위는 Flutter 기반 모바일 클라이언트와 클라이언트-서버 통신 계층이다. REST 요청·응답, SSE 이벤트 스트림과 HX 디자인 시스템 기반 플레이 화면을 담당한다. 메시지 순서와 멍등성, 세션 복구, 네트워크 지표 로깅 및 모바일-서버 통합 테스트를 포함한다. 본 보고서의 Flutter 화면과 정보 표현, 서버 통신과 비동기 처리, 사용자 관점의 저장·재개에 해당하는 영역이다.

3.18.3. 신승훈 — AI 엔지니어링과 생성 일관성 검증

신승훈(202355637)의 담당 범위는 AI 엔지니어링과 생성 모델의 일관성 검증 구조이다. Narrative/State 2계층의 서사 생성과 구조화된 상태 후보의 추출·검증, 구조화 출력(structured output), 프롬프트 계약(prompt contract)과 StateGuardrail 검증 조건을 담당한다. 상태 불일치, 아이템 환각, 인물 등장과 참조 오류, 전투 결과 왜곡, 텍스트-이미지 불일치 사례의 테스트 및 기준 비교 평가 도구와 로그 분석 파이프라인을 포함한다. 본 보고서의 장면·선택 생성, 생성 검수와 상태 보호, 평가 자료 수집과 분석에 해당하는 영역이다.

위 역할은 구성원별 담당 범위를 나타낸다. 코어·통합 영역은 제3.3~3.5절·제3.9~3.11절·제4.3절, 모바일·통신 영역은 제3.12~3.15절, 생성·검증 영역은 제3.6~3.8절·제4.4~4.7절에서 구현과 평가 근거를 제시한다.

3.19. 산업체 멘토 의견과 반영

2026년 8월 6일 산업체 자문에서는 생성 모델과 시스템의 책임을 분리한 목표와 검증 구조를 긍정적으로 평가하였다. 보완 의견은 핵심 처리 흐름과 개선 전후 사례를 중심으로 결과를 설명하고, 탐지 성능과 상태 보호를 동일 조건의 정량 비교로 확인하는 것이었다. 본 과제에서는 이 의견을 통합 처리 사례와 구성요소별 평가에 반영하였다.

표 11. 산업체 멘토 의견과 반영 내용

자문 의견	수행한 대응	결과의 범위
핵심 처리 흐름과 전후 사례 제시	파티 수락 전후의 선택·장면·명단 연결, 구매 후보 거절 전후의 상태 비교	행동 전후의 통합 작동과 보호 사례를 확인
생성 모델과 시스템의 책임 분리 유지	확정 상태·완료 사건·생성 후보의 권한과 적용 순서를 구현	상태 보호와 서술 정확성을 구분하여 평가
정밀도·재현율·위양성률과 상태 오염 평가	490개 표시 단위의 검출 성능과 거절·복구 전후 상태를 대조	검출 성능의 한계와 상태 보존의 작동을 확인
동일 조건 적용 전후 정량 비교	장기 기억 입력 FULL/M0 10쌍 비교, 동일 원후보의 검수 적용 여부에 따른 잔존 분석	기억 입력 비교는 수행. 검수 분석은 원후보 기준이며 전체 최종 출력의 통제 비교는 미수행

4. 연구 결과 분석 및 평가

4.1. 평가 목적과 실험 구성

평가에서는 선택과 실제 상태의 연결, 경험의 후속 입력 전달, 상태 복원이라는 통합 기능의 작동을 확인하였다. 특히 선정한 자료의 파티·이동 상태 비교 43건과 분리 로드 24 회·재개 응답 240필드가 일치하였다. 확정된 전투의 피해와 승패가 표시 문장에 이어지는 정상 사례와, 구매 완료 근거가 없는 후보를 거절하고 상태를 보존한 사례도 관측하였다. 한편 일부 상태 설명 오류는 검수를 통과하였다. 따라서 구현한 통제 구조의 작동과 의미 검출의 성능을 구분하여 평가한다.

표 12. 연구 질문별 확인 결과

연구 질문	확인한 결과	근거와 적용 범위
상태 변경 권한을 분리하고 잘못된 후보의 적용을 통제할 수 있는가	구매 후보 거절 후 소지금·소유물 보존, 오류 회복 서술과 무관하게 실제 MP 유지	구매 후보 거절과 필드 대기의 전후 상태, 후보 차단과 상태 보존을 구분하여 관측
최근 맥락과 축적된 경험을 현재 생성에 연결할 수 있는가	장면 원문이 요약을 거쳐 후속 입력으로 전달. 별도 FULL/M0 비교에서 자연 회상 6/10 대 0/10, 새 사실 반영 7/10 대 0/10	전달 사례 및 과거 모델·LLM 기준 판정의 탐색적 비교. 계층별·하이퍼그래프의 독립 효과는 미측정
선택·진행·재개 흐름에서 작동을 관측할 수 있는가	파티 수락의 화면·장면·명단 연결, 기대 상태 43건 및 저장·재개 비교 일치	여러 개발 버전에서 사후 선정한 8세션의 기능 평가와 별도 사례·복원 검사. 표본 선정 조건은 제4.2절에 명시

자동 플레이어의 선택·장면·생성·검수 응답을 상태 변화와 연결하여 평가하였다. 기억 입력의 비교와 검출기 표집 평가는 각 질문에 맞는 별도 조건으로 수행하였다.

운영 평가는 2026년 9월에 0.1층과 1차 직업 범위의 DebugMode에서 수행하였다. 각 세션은 시작 장면 이후 15행동을 목표로 하였으며 게임 생성 모델은 Gemini 3.8 Flash, LOW thinking 설정을 사용하였다. 자동 플레이이므로 사람의 몰입이나 모바일 조작의 사용성을 측정한 실험과는 구별된다. 장면 수에는 시작 장면이 포함되며, 행동 시도 수와 확정된 행동 수는 따로 집계하였다.

기능 평가는 개발 과정의 16개 실행에서 적격성을 검토하여 사후 선정한 8세션을 대상으로 하였다. 평가 대상은 120확정행동과 시작 장면을 포함한 128표시장면이다. 선정 기준과 제외 이유는 다음 절에서 설명한다.

후보 거절과 상태 복구는 동일 구현의 6세션 기록을 보조 자료로 사용하였다. 이 중 3세션은 기능 평가군에도 포함되므로 두 집합을 합산하지 않는다. 기억 입력 비교와 검출기 평가는 각각의 실험 조건과 표집 설계에 따라 별도로 해석한다.

표 13. 평가 자료와 목적

자료	규모	평가 목적
최종 기능 평가	적격 8세션·120확정행동·128장면	선택·상태·기억·검수의 연결
거절·복구 보조 자료	동일 구현 6세션·90목표행동	후보 거절 이후 상태 보존, 검수와 최종 표시의 연결
개발 실행 전체	16실행·240목표행동	사례 선정과 미완료의 배경
기억 비교	FULL/M0 10쌍·80예정 문항	장기 기억 입력 조건의 차이
검출기 평가	490개 판정 표본	정밀도·재현율·위양성률

개발 실행 전체에서는 215행동이 수락되었고 11실행이 목표를 완료하였다. 기능 분석에 선정한 8세션은 121회 시도에서 120행동을 확정하였다.

4.1.1. 자동 플레이의 행동과 종료 조건

일반 플레이 수집은 현재 서버가 제시한 선택 중 하나를 무작위로 고르는 정책을 사용하였다. 캐릭터와 시작 장비는 시작 API가 허용하는 값에서 선택하고, 한 세션의 목표는 시작 장면 이후 15행동으로 두었다. 시스템 조작을 포함하는 수집에서는 사용 가능한 아이템·장비 조작도 정책에 따라 실행하였다. 이 정책은 가능한 경로를 탐색하기 위한 것이며 실제 사용자의 선호나 숙련도를 대표하지 않는다.

행동 전 상태와 선택, 요청 결과와 행동 후 상태를 기록하고, 생성 원문·검수·정산 기록을 세션과 행동 식별자로 연결하였다. 장면 하나에도 생성·추출·선택 호출이 포함되므로 장면 수, 논리 작업 수, 실제 API 전송 수는 별도로 집계하였다. 성공 응답만 골라 전송 횟수를 계산하지 않고 실패한 전송과 사용량 미확정도 남겼다.

수집 실행의 행동 시도 한도는 목표 행동당 최대 2회, 15행동 세션당 최대 30회이다. 읽기 요청의 HTTP 500 재시도는 최대 2회이고 변경 요청은 전송 단계에서 한 번만 수행한다. 이와 별개로 애플리케이션의 복구 가능 여부를 확인하여 후속 시도를 처리한다. 목표 도달, 게임 종료, 오류 또는 시도·예산 한도에서 수집을 종료한다. 복구 응답 후에도 같은 행동의 시도 한도에 도달하면 자동 플레이가 종료되므로, 목표 미달은 정책상 미완료와 실제 장애를 구분한다. 한도 이후의 진행 가능성은 미측정으로 남긴다.

일반 플레이는 초기 시각이나 대기 동작을 주입하는 고정 시나리오 없이 수집하였다. 반면 기억 비교는 평가용 사실을 미리 저장하고 지정 장면에서 질문하는 개입 실험이다. 같은 디버그·시작 조건의 실험으로 합쳐 해석하지 않는다. 또한 초기 조건을 고정하더라도 공급자의 생성 결과와 이후 플레이 경로까지 동일하게 재현되는 것은 아니다.

4.1.2. 평가 자료의 모델과 구현 조건

9월의 선택·상태·기억 평가는 Gemini 3.8 Flash/LOW 조건이다. 기능 평가 8세션은 여러 개발 버전의 실행에서 선정했으며, 거절·복구 보조 자료 6세션의 기준 버전은 22763725f이다. 기억 입력 비교와 검출기 평가는 b5421e9f 구현, Gemini 3.5 Flash-Lite/MINIMAL 조건이다. 파티 수락 화면은 9월 10일 리디아 실행, 공유 경험 공급 사례는 8월 1일 Gemini 3.1 Flash-Lite 실행에서 확인하였다. 두 대표 사례를 8세션 통계에 추가하지 않았다.

제3장은 본 과제에서 통합한 기능과 처리 경계를 설명한다. 제4장의 수치는 각 자료가 수집된 구현·모델 조건에서 해당 기능의 작동을 확인한 결과이며, 단일 최종 빌드 전체의 성능을 나타내지 않는다. 모델이나 코드가 다른 자료를 합쳐 하나의 성능 변화로 해석하지 않는다. 통합 사례, 기능별 상태 비교, 기억 입력의 통제 비교, 검출기의 표집 평가가 각각 어떤 주장을 뒷받침하는지 구분하였다.

4.2. 최종 평가 자료의 선정과 관측 범위


최종 분석의 선정 기준은 0·1층과 1차 직업에서 실제 승인한 선택과 결정적 상태의 관계를 관측할 수 있고, 확인된 구현 결함이 그 관계를 왜곡하지 않은 완주 세션이다. 서술에 사실 오류가 있다는 이유만으로 모두 제외하지 않았다. 예를 들어 공식 파티는 2인인데 서술과 기억이 3인으로 표현한 라이오넬 사례는 상태 권한과 서술 오류를 함께 관측할 수 있으므로 포함하였다.

원래 16개 개발 실행 중 11개가 목표 행동을 완료하였다. 완주 세션에서도 정확한 3인 수락의 명단 반영이 다음 행동으로 지연된 로건, 실제 위치와 시설 사용이 어긋난 헤베.

드림은 핵심 관계의 평가 대상에서 제외하였다. 미완료 5세션도 최종 기능 평가군에 포함하지 않았으며, 사망·진행 중단과 당시 관측은 개발 기록으로 보존하였다. 이 선정은 전체 플레이어의 무오류 여부를 판단하기 위한 무작위 표집이 아니다.

표 14. 최종 기능 평가에 선정한 세션

세션	확정 행동	표시 장면	관측 범위
카르나	15	16	선택과 정산, 회복 선택의 후속 전개
알레한드라	15	16	파티 정산과 전투 후 현재 상태 설명
시온	15	16	파티 가입과 오류 판정의 대상 구분
데미지	15	16	파티 정산과 경험 요약의 전달
지윤	15	16	가입·이동, 복구와 선택 이행
해럴드	15	16	이동·모집 정산과 전투 결과의 서술
라이오넬	15	16	정식 명단과 서술·기억의 불일치
바르바라	15	16	자원·파티 정산과 회복 서술
합계	120	128	관측 질문별 분석



선택과 상태의 관계를 관측할 수 있는지 사후 적격성 검토

선정한 자료의 관측량이며 전체 성공률을 뜻하지 않음

그림 12. 개발 실행에서 최종 기능 평가 자료를 선정한 범위

선정된 8세션에서는 121회 행동 시도 중 120행동이 확정되었다. 지윤의 한 행동은 인물 참조가 누락된 응답으로 복구된 뒤 후속 시도에서 성공하였으며, 실패한 시도도 분모에 포함하였다. 표의 15행동은 선정 세션의 관측량이다. 완주 여부를 선정 조건에 사용했으므로 이를 8/8 성공률이나 오류 없는 플레이어의 비율로 해석하지 않는다.

4.2.1. 미완료 실행과 후보 거절의 해석

거절·복구 보조 자료인 동일 구현 6세션에서는 4세션이 15행동 목표에 도달했으며, 전체 81/90행동과 87표시장면을 기록하였다. 루도비코와 리안논은 각각 10행동과 11행동 뒤 복구된 시도가 행동당 2회 한도에 도달하여 수집을 마쳤다. 이 값은 해당 수집 정책 아래의 관측량이다. 복구 불가능한 교착의 비율이나 최종 구현의 진행 성공률로 사용하지 않는다.

이 자료에서는 잘못된 장소 전제, 구매 정산이 없는 완료 후보, 인물 참조 누락이 관측되었다. 실패한 다섯 번의 복구 시도에서 비교한 HP·MP·골드·장비·아이템·정식 파티·위치는 전후에 유지되었다. 도달한 5·10·15행동 지점의 저장 복원은 16회 일치했고, 계획한 18회 중 두 번은 수집 종료로 해당 지점에 도달하지 못하였다.

따라서 목표 행동을 완료하지 못한 실행에서도 상태 보존의 작동은 평가할 수 있다. 반대로 상태가 보존되었다고 해서 사용자가 요청한 행동이 완료된 것은 아니다. 다음 절에서는 선택에 따른 정산, 후보 거절에 따른 보호, 사용자에게 표시된 문장의 정확성을 나누어 분석한다.

4.3. 선택 정산과 상태 일치

기능별 사례에서는 현재 장면과 사용자가 선택한 내용을 바탕으로 기대 상태를 정하고 실제 결과를 비교하였다. 파티 관련 선택 14건에서는 명단과 파티장을 각각 비교하였으며, 명시적인 이동에서는 위치를 15건 비교하였다. 따라서 총 비교 수는 명단 14건, 파티장 14건, 위치 15건을 합한 43건이다. 이 범위에서는 실제 값이 기대값과 일치하였다.

이 결과는 선정한 파티·이동 사례에서 선택에 따른 기대 상태가 실제 실행 결과로 연결되었음을 보여준다. 43건은 동일한 파티 선택의 두 필드 비교를 포함한 상태 비교 횟수이다. 또한 명단 반영 지연과 위치·시설 불일치가 확인된 실행은 앞 절의 선정 과정에서 제외되었다. 따라서 이 수치는 선정된 기능 사례의 일치 결과이며 전체 개발 실행의 정산 정확도를 추정하지 않는다.

전체 상태 비교 자료는 10개 필드에 대해 시작 장면 8개와 행동 시도 121개를 연결한 1,290행으로 구성하였다. 그중 1,178행은 해당 근거와 일치하였고 112행은 판단 근거가 부족하였다. 일치한 행에는 위의 사전 기대 비교 43건 외에도 변경이 없다는 조건에서의 보존 986건과 기타 정산 기록·산술에 따른 149건이 포함된다. 근거 수준이 다른 값을 하나의 게임 정확도로 환산하지 않았다.

표 15. 상태 비교의 근거와 결과

비교 근거	행 수	의미
장면·선택에서 정한 기대	43	명단·파티장·위치의 기대값 일치
변경이 없을 때의 보존	986	해당 조건의 상태 유지
기타 정산 기록·산술	149	기록에 따른 값의 일치
근거 부족	112	성공·실패 판정 보류
합계	1,290	서로 다른 근거 수준의 비교

별도의 저장 확인에서는 분리된 상태 로드 24회의 해시 일치와 공개 재개 응답 240필드의 스냅샷 일치를 확인하였다. 이는 저장된 상태가 복원되는지를 보는 검사이다. 상태의 값이 게임 규칙의 독립적인 정답인지, 실제 서버 프로세스 재시작과 모바일 강제 종료 후에도 동일한 운영 품질을 갖는지는 추가 조건의 검증이 필요하다.

4.4. 상태 보호와 서술의 정확성

확정한 사건은 정상적인 전투 장면의 내용과 후속 판단에도 연결되었다. 바르바라의 뿔 토끼 전투에서는 시스템이 피격, 기본 공격에 의한 처치, HP 105→94를 확정하였다. 실제 표시 문장은 뿔 박치기를 받은 뒤 지팡이로 반격하여 적을 처치하는 순서로 이어졌으며, “연속된 충격으로 체력 수치는 뚜렷한 손실을 가리키고 있었다.”고 현재 상태를 묘사하였다. 이어 다른 인물이 거점 정비나 동행을 권하면서 다음 판단으로 연결하였다. 이 사례는 결정적 전투 결과를 나열하는 데 그치지 않고, 확정된 피해와 승패를 장면의 행동·반응으로 표현한 결과이다.

거절·복구 보조 자료의 리안논 실행에서 무인 상점의 기본 목궁을 구매하는 선택을 했을 때, 생성 후보는 골드 차감과 목궁의 인벤토리 수납이 완료되었다고 서술하였다. 그러나 이번 행동에는 이를 뒷받침하는 구매 정산이 없었다. 검수는 구매 완료와 새 무기 확보를 전제로 한 후속 표시 단위를 거절하였고, 해당 시도는 복구 처리되었다. 응답의 소지금은 100G로 유지되었으며 초심자 단검·방패·경갑과 인벤토리에도 변화가 없었다.

해당 선택은 열린 자연어 선택으로 처리되었으며, 실행 기록의 유형은 서사 진행(narrative_only)이었다. 완료된 정산은 0건이고 시스템 완료 사실에도 구매 결과가 없었다.

표 16. 구매 완료 후보와 실제 처리 결과의 대조

관측 대상	실제 문장 또는 상태
생성 후보의 완료 주장	“등록된 골드가 차감되자 인벤토리에 가벼운 목궁 한 자루가 정식으로 수납되었고”
검수에 제공된 실행 결과	완료된 정산 0건, 구매 완료 사실 없음
검수 판정과 표시	구매 완료와 구매 후 행동을 서술한 두 단위를 거절. 해당 후보는 반환된 표시 내용에 포함되지 않음
소지금	행동 전 100G → 거절 후 100G
소유물·장비	아이템 기록과 장비가 행동 전후 동일. 목궁 추가 없음

이 사례에서 사용자의 구매 의도는 실제 구매 완료의 근거로 인정되지 않았다. 잘못된 후보가 표시·저장되지 않고 마지막 확정 상태로 돌아갔으므로 상태 보호의 작동을 확인할 수 있다. 사용자가 원한 구매는 완료되지 않았으며, 후속 요청의 인물 참조 오류와 복구를 거쳐 자동 플레이의 시도 한도에서 수집이 종료되었다. 후보 거절, 상태 보존, 요청한 행동의 완료는 각각 별도로 평가해야 한다.

반면 상태가 정확해도 서술 오류는 남을 수 있었다. 해럴드의 전투 장면에서는 전투 중 HP가 113에서 75로 감소한 뒤 레벨업을 거쳐 현재 HP가 149/149가 되었다. 생성 입력에는 전투 결과와 현재 자원이 함께 제공되었지만, 최종 표시의 마지막 부분은 “예상치 못한 기습으로 인해 체력이 크게 소모된 상태였다.”고 표현하였다. API의 HP는 149로 유지되었으므로 수치의 직접 오염은 확인되지 않았으나, 과거의 피해를 현재의 자원 부족으로 이어 쓴 설명은 잘못되었다.

표 17. 전투 후 상태 설명의 오류 사례

단계	내용
생성 입력	전투 중 HP 113→75, 보상 후 현재 HP 149/149
최종 표시	“예상치 못한 기습으로 인해 체력이 크게 소모된 상태였다.”
검수	해당 표시 단위를 수용
최종 상태	HP 149/149. 현재 부족 상태로 바뀌지 않음
사용자에게 보인 결과	현재 상태와 맞지 않는 묘사 표시

이 사례는 전투 중 피해를 입었다는 과거 사건과 보상 후 현재 상태를 구분해야 함을 보여준다. 검출기가 단어의 존재만 보는 것이 아니라 어느 시점의 상태를 설명하는지 판단해야 하기 때문이다. 동일하게 MP가 변하지 않았는데 자연 회복을 암시하는 표현이 나타난 경우도 있었다. 상태 값의 보존을 곧바로 서술 검증의 성공으로 세지 않았다.

오탐 사례도 함께 검토하였다. 몬스터의 사냥 맥락에서 사용한 ‘리스폰’ 표현을 플레이어의 영구 사망 규칙 위반으로 읽는 경우에는 대상의 구분이 잘못되었다. 현재 자원이 제공되지 않은 다른 인물의 부족 발언도 실제 수치와 충돌했다고 확정할 수 없다. 검수 품질을 높이기 위해서는 오류를 놓치는 경우뿐 아니라 정상적인 표현을 잘못 거절하는 경우도 다루어야 한다.

4.4.1. 필드 대기과 MP 불변 사례

바르바라의 필드 대기 장면은 신록의 평야에서 진행되었으며, 생성 입력의 현재 자원은 MP 11/106이었다. 바르바라는 마나를 채운 뒤 움직이자는 취지의 대기를 선택하였다.

후속 서술은 '비거점 필드인 탓에 자연 회복으로 차오르는 마력의 속도는 더디기 짝이 없었다'고 표현하였다. 그러나 실제 MP는 대기 전 11에서 대기 후에도 11로 유지되었다. '회복이 느리다'는 표현은 회복 자체가 없는 규칙과 다르므로 이 문장은 서술 오류이다. 동시에 그 표현이 실제 MP 증가로 이어지지 않았다는 점에서 상태 변경 권한의 분리가 관측된다.

구매 후보 거절 사례와 이 사례의 결과는 다르다. 구매 사례에서는 잘못된 후보의 표시와 저장을 차단하였다. MP 사례에서는 오류 문장이 표시되었으나 실제 값은 유지되었다. 상태 보호가 작동했다고 해서 의미 검수가 성공했다고 평가할 수 없다는 점을 보여준다.

4.4.2. 검수 결과와 최종 표시의 연결

검수 결과가 실제 사용자 출력에 적용되는지는 동일 구현의 6세션 전체에서 확인하였다. 시작 장면 6개를 제외한 86번의 행동 시도를 추적하고, 행동 식별자로 생성·검수 입력·판정·API 응답을 연결하였다. 81번의 확정 행동에서 표시된 517개 단위는 모두 같은 행동의 검수 입력 원문과 일치했으며 각 단위에 수용 판정이 있었다. 또한 86번의 응답 모두에서 API의 표시 문장과 자동 플레이가 기록한 문장이 일치하였다. 이 결과는 검수한 내용과 실제로 소비한 내용이 연결되어 있음을 보여준다.

최종 표시의 사실 대조에서는 81확정행동의 원문을 읽고, 주인공의 현재 자원·소지품·공식 파티 및 완료 사건에 관한 주장을 당시 상태와 관련 생성 입력에 대응시켰다. 제안·계획·감정 표현을 실제 정산의 완료와 구분하고, 전투 중 피해와 보상 후 현재 상태도 별도로 읽었다. Codex가 원문과 당시 상태·생성 입력을 대조하여 사실 충돌 여부를 검토하였다. 이 결과는 사례 분석에 사용했으며, 모든 문장의 독립적인 정답 라벨이나 전체 오류를 산출에는 사용하지 않았다.

표 18. 후보 판정과 최종 출력의 처리 결과

처리 결과	행동 시도 수	최종 출력에서 확인한 내용
검수 후 장면 확정	81	표시 517단위가 같은 행동의 검수 원문·수용 판정과 연결
상태·완료 또는 공간 범위 판정에 따른 후보 거절	4	새 후보를 확정하지 않고 이전 표시 장면 유지
응답 계약 실패에 따른 복구	1	추출·의미 검수 단계 이전에 중단하고 이전 표시 장면 유지
합계	86	확정과 복구를 구분한 행동 시도 전체

네 번의 후보 거절 중 리안논의 두 구매 시도에는 정산되지 않은 구매·장비 확보 주장에 대한 거절 판정이 있었고, 해당 원문은 응답에 표시되지 않았다. 루도비코의 두 시도는 현재 장면의 공간 범위 판정에서 거절되었다. 다섯 번의 복구 모두 응답의 장면 식별자와 표시 본문이 이전 확정 장면을 유지하였다. 이 과정은 잘못된 후보를 경고로만 남기는 것이 아니라 장면 확정과 사용자 출력에 반영하는 집행 경계의 작동을 보여준다.

수용 판정과 표시의 일치는 문장의 사실 정확도와 다르다. 실제 대조에서는 앞의 현재 HP 설명 외에도, 소유 기록에 없는 활과 화살통의 점검을 서술하거나 과거의 포션 사용을 새로운 소비·회복처럼 표현한 사례가 있었다. 해당 장면의 실제 장비와 포션 수량은 그 서술대로 변경되지 않았다. 앞의 MP 사례처럼 수용된 문장에도 오류가 남을 수 있다. 또한 후보 거절 후 다른 선택으로 진행한 경우와 같은 선택을 다시 생성한 경우, 응답 미수신에 따른 재호출은 서로 다른 처리이다. 본 비교는 검수와 출력의 연결 및 후보 미노출을 확인한 것으로, 재생성된 전체 문장의 독립적인 사실 판정이나 검수 없는 별도 실행과의 오류율 비교를 대신하지 않는다.

4.5. 기억 전달의 정상 사례와 오류 사례

데이지 세션에서는 다른 인물이 말한 포션 소모 경험이 장면 원문에서 요약을 거쳐 이후 입력의 과거 사건으로 전달되었다. 이전 대화에서 얻은 경험을 다음 장면의 맥락으로 사용할 수 있는 경로가 작동한 사례이다. 이 내용은 해당 인물의 경험이라는 출처를 가지며, 게임 전체에 적용되는 새로운 포션 규칙으로 취급하지 않았다.

라이오넬 세션에서는 정식 가입이 완료되지 않은 카즈키를 포함한 3인 진형 서술이 요약과 후속 입력에 전달되었다. 정식 파티 명단은 2인으로 유지되었지만, 잘못된 서술은 기억을 따라 남았다. 이는 기억의 전달 경로가 동작하더라도 원문에 있던 오류가 후속 생성의 근거로 재사용될 수 있음을 보여준다.




그림 13. 정상 경험과 잘못된 서술의 기억 전달 비교

두 사례를 함께 보면 기억의 평가에는 두 질문이 필요하다. 첫째, 이후 장면에 필요한 경험을 실제로 전달했는가. 둘째, 그 경험의 사실과 출처가 올바르게 유지되었는가. 첫 번째만 확인하면 오류의 재전파를 성공으로 평가할 수 있다.

4.5.1. 인물과 연결된 공유 경험의 활용 사례

관계 하이퍼그래프는 현재 만나는 인물과 함께 겪은 사건을 후속 장면의 맥락으로 제공한다. 2026년 8월 1일 메리·트리톤 사례에서는 파티 결성과 이동 합의를 담은 경험 요약이 이후 생성 요청의 트리톤 관련 공유 경험으로 다시 제공되었다. 이 사례는 Gemini 3.1 Flash-Lite를 사용한 당시 구현의 동작 사례이며, 앞의 9월 기능 평가 표본과 별도로 제시한다.

표 19. 공유 경험의 생성과 후속 장면 연결

단계	실제 기록과 연결
경험 요약	“트리톤의 제안을 받아들여 파티를 결성하고, 보스룸 공략을 위해 1층으로 이동하기로 합의했다.”
후속 입력	‘트리톤과의 경험’ 항목에 같은 요약 원문을 공급
후속 장면	“저 멀리서 트리톤이 미간을 찌푸린 채 나를 쫓아오는 것이 느껴졌지만”

표의 문장은 각 기록에서 발췌한 내용이다. 파티 결성과 이동을 논의한 사건이 요약으로 남고, 관련 인물의 공유 경험으로 다시 공급된 뒤에도 두 인물의 관계가 장면에 이어졌다. 생성 문장과 실제 표시 문장의 일치도 확인하였다.

이 사례는 인물과 연결된 경험을 후속 생성에 공급하고, 생성 결과를 플레이 흐름으로 이어 주는 경로를 보여준다. 관계·경험 검색을 게임에 통합한 구현 성과의 근거이다. 다만 다른 기억 맥락도 함께 제공되었으므로, 이 결과만으로 하이퍼그래프의 독립적인 품질 향상이나 일반적인 기억 정확도를 산정하지 않는다.

4.6. 장기 기억 입력 비교

장기 기억의 입력 효과는 FULL과 M0 조건을 비교하였다. FULL은 장기 기억을 입력에 제공하고 M0는 해당 입력을 제외한 조건이다. Gemini 3.5 Flash-Lite/MINIMAL과 당시 구현에서 10쌍의 실행을 수행하였으며, 지연 회상, 새 사실 반영, 근거가 없을 때 추측을 자제하는 능력을 평가하였다. 총 80개의 예정 확인 문항을 기준으로 하고, 응답·판정이 없는 문항도 분모에 남겨 성공으로 세지 않았다.

표 20. 장기 기억 입력 조건의 비교

평가 항목	FULL	M0	관측 차이
지연 회상	6/10	0/10	+60%p
새 사실 반영	7/10	0/10	+70%p
근거 없을 때 추측 자제	10/20	10/20	0%p

표 21. 기억 비교 예정 문항의 결과 구성

조건·문항	예정	판정 성공	판정 오답	결과·판정 없음
FULL 회상	10	6	4	0
M0 회상	10	0	7	3
FULL 갱신	10	7	2	1
M0 갱신	10	0	7	3
FULL 추측 자제	20	10	4	6
M0 추측 자제	20	10	3	7
합계	80	33	27	20

예정 80문항 중 60문항에 응답과 기준 판정이 있으며, 판정된 문항에는 판정 불가 라벨이 없었다. 결과·판정이 없는 20문항 중 16문항은 질문 주입 기록이 없고, 4문항은 질문 주입 기록이 있으나 대응하는 응답 결과가 없다. 따라서 이 20문항을 모두 실제 오답이나 질문 미도달로 해석하지 않는다. 판정된 문항만 보면 회상은 FULL 6/10 대 M0 0/7, 갱신은 7/9 대 0/7이었다. 관측 차이가 전적으로 질문 미도달에서 발생한 것은 아니며, 결과가 있는 문항에서도 기억 입력 조건의 차이가 나타났다. 이 보조 비교는 조건별 진행 차이가 포함된 예정 분모의 결과와 함께 해석한다.

자연 회상과 새 사실 반영에서는 FULL 조건이 더 많은 문항을 충족하였다. 이 결과는 저장한 사실을 실제 생성 입력에 공급하는 설계의 가치를 뒷받침한다. 근거가 없는 경우의 추측 자제에서는 두 조건의 차이가 관측되지 않았다. 따라서 기억 입력의 효과는 회상·갱신과 추측 자제로 나누어 해석한다.

이 비교의 판정에는 LLM이 생성한 pseudo-label을 사용하였다. 독립적인 인간 정답을 구축한 실험은 아니며, 네 기억 계층의 기여를 하나씩 제거하여 측정한 실험도 아니다. 본 결과는 해당 모델·문항·판정과 조건별 진행 차이를 포함한 장기 기억 입력의 탐색적 비교이다.

4.6.1. 기억 비교의 조건과 확인 문항

FULL과 M0는 기억 쓰기와 시작 상태를 동일하게 두고 장기 기억을 프롬프트에 투영하는 경로의 유무를 비교한다. 평가용 사실이 기록에 존재하는지와 모델이 그 사실을 실제로 입력받는지를 분리하기 위한 조건이다. 각 쌍의 시작 상태·시나리오·모델·추론 수준을 맞추었다. 후속 생성 결과와 선택 궤적의 동일성을 가정하지는 않는다.

고정 시나리오는 6장면 안에 네 문항을 배치하였다. 암구호 '청동매 7319'를 미리 기록한 뒤 두 번째 확인 시점에 정확한 값을 묻는다. 집결 장소는 '북문 12번 표지석'에서 '서쪽 수로 88번 사다리'로 변경한 후 현재 유효한 장소를 묻는다. 기록에 없는 유물의 보관 위치와 관측되지 않은 인물의 실제 이름은 추측을 자제해야 하는 두 문항이다. 평가용 문항은 기억 접근을 확인하도록 구성된 자극이며 자연 플레이 전체를 대표하는 질문은 아니다.

기준 판정은 응답이 제공된 사실을 충족하는지, 폐기된 사실을 현재 정보로 사용하지 않는지, 근거 없는 질문에 새 사실을 만들지 않는지를 본다. 10쌍에 두 조건과 네 문항을 적용하므로 예정 분모는 80개이다. 응답한 문항만 남기지 않고 미도달·미채점·판정 불가도 예정 분모에 포함하였다. 따라서 결과에는 기억 검색과 답변의 정확성뿐 아니라 해당 질문까지 진행할 수 있었는지도 영향을 준다.

4.6.2. 기억 조건에 따른 실제 생성 내용

동일 시작 조건의 한 쌍(seed 103)에서 회상과 갱신 문항의 실제 생성 내용을 비교하였다. FULL의 회상 장면에는 "내 기록에 남아 있던 암구호인 청동매 7319를 조용히 되뇌며"라는 문장이 나타났다. M0에서는 "비밀 통행 암구호 같은 것은 내 시스템 기록 어디에도 존재하지 않았다"라고 서술하였다. 평가용 사실은 두 조건의 기록에 존재했으므로, 이 차이는 사실의 저장 여부와 생성 입력에서의 접근 가능성을 구분해야 함을 보여준다.

집결 장소를 변경한 뒤 FULL은 "서쪽 수로 88번 사다리라는 최신 유효 장소"를 떠올렸으며, 장면 말미에도 그곳으로 이동할지 판단하는 내용을 제시하였다. 같은 쌍의 M0는 광장으로 돌아와 다음 행보를 논의하는 장면을 생성했으나 변경된 집결 장소를 언급하지 않았다. FULL에서는 기억이 입력에 포함되는 데서 그치지 않고 후속 서술의 구체적인 장소와 판단 맥락에 사용되었다.

표 22. 동일 시작 조건에서의 기억 활용 사례

확인 항목	FULL에서 나타난 내용	M0에서 나타난 내용
암구호 회상	“내 기록에 남아 있던 암구호인 청동 매 7319를 조용히 되뇌며”	“비밀 통행 암구호 같은 것은 내 시스템 기록 어디에도 존재하지 않았다”
변경된 장소 반영	“서쪽 수로 88번 사다리라는 최신 유효 장소”	“다시 광장 내 다른 구역으로 이동하거나 파티원과 다음 행보를 논의할 수 있다.”

표의 인용은 같은 시작 조건 쌍의 해당 장면에서 발췌한 문장이다. M0의 집결 장소 미언급 여부는 발췌문뿐 아니라 해당 장면 전체에서 확인하였다. 이 쌍은 앞의 전체 결과를 이해하기 위한 사례이며 별도의 추가 표본은 아니다. 모든 FULL 실행이 성공한 것은 아니다. 다른 쌍(seed 101)의 갱신 장면은 서쪽 수로 방향만 언급하고 정확한 표지인 88번 사다리를 재현하지 못해 문항을 충족하지 못하였다. 시작 조건은 맞추었지만 이후의 인물·선택 경로는 달라졌으므로 문장 표현 자체의 일대일 우열로 해석하지 않는다. 전체 10쌍의 결과와 함께 보면, 필요한 기억을 입력에 제공하는 구조가 회상과 갱신을 지원하는 한편 정확한 세부의 재사용까지 항상 보장하지는 않음을 알 수 있다.

4.7. 검출기 성능과 후보 차단

검출기 평가는 pseudo-label 490개를 사용하였다. 검출기 양성 35개는 전수, 음성은 455개를 표집한 자료이다. 표집된 음성의 비율이 실제 모집단과 다르므로 최종 지표에는 표본 가중치를 적용하였다. 비가중 혼동행렬은 TP 16, FP 19, FN 3, TN 452이며, 가중치를 적용한 값은 TP 16, FP 19, FN 33.475, TN 4724.525이다.

평가 단위는 생성 응답의 sequence, 즉 하나의 표시 단위이다. 하나의 sequence에 복수 문장이 포함될 수 있으므로 490개를 서로 독립적인 자연어 문장 490개로 해석하지 않는다. 표집 모집단은 4,793개이며 검출기 양성 35개와 음성 4,758개로 구성된다. 음성은 시나리오·기억 조건·장면 유형별 층에서 표집하였다. 양성은 가중치 1을, 음성은 해당 층의 포함 확률의 역수를 적용하였다. 예를 들어 전투 FULL의 일반 장면 음성은 502개 중 60개를 뽑았으므로 각 항목의 가중치는 502/60이다.

표 23. 검출기 평가의 시나리오별 표집 구성

시나리오·조건	일반 음성	시작 음성	사망 음성	양성 전수
전투 FULL	502/60	51/10	해당 없음	7
전투 M0	488/30	45/10	9/9	3
탐험 FULL	591/40	49/10	해당 없음	4
탐험 M0	401/10	46/10	해당 없음	1
시설 FULL	310/30	48/10	해당 없음	3
시설 M0	427/40	49/10	해당 없음	4
기억 FULL	291/20	44/10	해당 없음	2
기억 M0	228/20	46/10	해당 없음	2
사회 FULL	511/30	49/10	6/6	3
사회 M0	524/60	43/10	해당 없음	6

표의 음성 각 칸은 모집단 수/표본 수이며, 일반·시작·사망은 서로 다른 표집층이다. 시나리오·기억 조건·장면 유형을 조합하여 자료가 존재하는 총 22개 표집층을 구성하였으며, 음성 각 항목의 가중치는 해당 칸의 모집단 수를 표본 수로 나눈 값이다. 양성 열은 장면 유형을 합친 전수 수이며 모두 가중치 1이다. 전체 음성은 4,758개 중 455개, 양성은 35개 전부로 표본 490개를 구성한다.

판정자는 후보 원문과 그 장면의 상태·정산 근거를 대조하여 완료·상태 주장을 분해한다. 제안·질문·계획·비유 자체를 완료 주장으로 세지 않는다. 각 주장을 지지됨, 충돌함, 근거 없음, 판정 불가로 구분하고, 충돌하거나 근거 없는 주장이 하나라도 있으면 해당 표시 단위를 위반으로 판정한다. 여기서 기준 라벨은 독립적인 인간 정답이 아니라 기존 LLM 판정 자료이다. 판정 모델의 정확한 식별자와 모든 호출 설정이 보존된 평가 메타데이터에서 확인되지 않아 동일 판정 실행의 재현에는 제약이 있다.

정밀도는 검출기가 오류라고 표시한 항목 중 기준 라벨이 오류인 비율이고, 재현율은 기준 라벨이 오류인 항목 중 검출기가 찾아낸 비율이다. 위양성률은 정상으로 판정된 항목을 오류라고 표시한 비율이다. 이 지표들은 서로 다른 실패를 보여주므로 함께 제시하였다.

표 24. 검출기 평가 지표

지표	계산	결과
정밀도	$TP / (TP + FP)$	45.71%
재현율	$TP / (TP + FN)$	32.34%
F1	$2TP / (2TP + FP + FN)$	37.88%
위양성률	$FP / (TN + FP)$	0.40%

기준 라벨과 대조한 결과, 검출기는 일부 정상 표현을 오류로 분류하고 오류 항목 일부를 놓쳤다. 낮은 위양성률과 함께 정밀도·재현율을 고려하면, 정상 표현의 보존과 오류 포착을 각각 개선할 필요가 있다.

후보 차단에의 영향은 기준 라벨이 오류로 판정한 원문 표시 단위가 최종 기록에 그대로 남는지 비교하였다. 여기서 원문 19개는 검출기의 위양성 19개와 구분되는 오류 원문 집합이다. 이 원문 중 최종 기록에서 발견된 것은 2개였으며, 비가중 감소는 89.47%, 표본 가중 감소는 49.25%였다. 오류 원후보 19개의 가중합은 49.475이고, 잔존한 두 원문의 가중치는 14.775와 10.3333으로 합계 약 25.1083이다. 따라서 가중 감소는 $1 - 25.1083 / 49.475$ 로 계산하였다. 비교 기준인 G0는 별도 플레이 실행이 아니라 같은 원후보를 검수 없이 표시한다는 가정이다. 검수 적용 자료에는 기억 FULL과 M0의 실행이 함께 포함된다.

이 비교는 원후보의 잔존을 측정한 것이므로 대체 후보에 새로 생긴 오류까지 포함한 전체 노출 감소율은 아니다. 본 연구는 후보를 거절하는 집행 기능을 확인하는 한편, 실제로 사용자에게 전달되는 전체 출력의 정확성은 더 넓은 평가가 필요함을 확인하였다.

4.7.1. 판정 신뢰성과 해석의 한계

동일한 490개 표시 단위에 대한 LLM 판정 A와 B는 462개에서 일치하고 28개에서 불일치하여 단순 일치율이 94.29%였다. A는 정상 487개·위반 3개, B는 정상 463개·위반 26개·판정 불가 1개로 분류하였다. 일치한 462개에는 두 판정의 공통 라벨을, 불일치한 28개에는 제3 판정을 포함한 다수결 라벨을 사용하였다. 정상·위반·판정 불가의 3개 명목 라벨로 계산한 Krippendorff의 α 는 약 0.039였다. 정상 항목이 많아 전체 일치율은 높지만 위반 판정 수는 크게 달랐으므로, 높은 단순 일치율만으로 오류 판정의 신뢰성을 충분히

설명하기는 어렵다. 따라서 검출 성능은 해당 표집과 기준 라벨에 조건부인 탐색적 수치이며 독립 인간 평가를 대체하지 않는다.

또한 sequence 단위의 오탐과 장면 전체 차단 영향은 다르다. 한 표시 단위가 거절되면 같은 후보의 정상적인 다른 문장도 함께 표시되지 않을 수 있다. 실제 사용자에게 도달한 오류량을 평가하려면 원후보뿐 아니라 재생성된 후보와 최종 표시까지 연결하여 판정해야 한다.

4.8. 운영 비용과 적용 범위

운영 비용은 입력·출력·캐시 입력 토큰을 구분하여 계산하였다. 기능 평가 8세션의 관측 비용은 5,118.71원 이상이며, 선정 전 16개 개발 실행 전체에서는 9,091.11원 이상이었다. 8세션은 전체 개발 실행에 포함되므로 두 값을 합산하지 않는다. 일부 실패 전송의 사용량이 확정되지 않아 관측 가능한 비용의 하한으로 해석한다. 실험 집계에 사용한 단가는 100만 토큰당 일반 입력 0.75달러, 출력 3.75달러, 캐시 입력 0.075달러이며 환율은 1달러당 1,350원이다. 전체 입력에서 캐시 입력을 제외한 양에 일반 입력 단가를 적용하고, 캐시 입력과 출력 비용을 더한 뒤 원화로 환산하였다.

이 비용에는 장면 생성뿐 아니라 기억 요약·검수·선택 생성 등 플레이 흐름의 작업이 포함된다. 따라서 장면 수를 모델 호출 수로 바꾸어 비용을 계산하지 않았다.

운영 비용은 초기 층의 짧은 자동 플레이 조건에서 측정한 값이다. 상위 층이나 장기 진행의 비용, 역할 분리로 인한 절감 효과를 이 집계에서 추정하지 않는다.

4.9. 종합 평가와 계획 대비 수행 범위

파티 수락과 상태 비교는 선택의 실행 가능성을, 경험 전달과 FULL/M0 비교는 기억 입력의 가치를 뒷받침한다. 구매 후보 차단과 복구는 오류 후보를 상태 확정에서 분리하는 기능을 보여준다. 동일 구현 6세션의 81개 행동 결과·517개 표시 단위를 검수 원문 및 수용 판정과 연결하여, 검수 결과가 실제 출력으로 이어지는 집행 경계도 확인하였다. 의미 검출의 한계와 오류 기억의 재사용도 함께 관측하였다. 이 결과는 실행 권한과 오류 전파 경계를 구현하고 이를 실제 플레이어의 상태·기억·표시에 연결한 아키텍처의 성과를 보여준다.

착수·중간 단계의 평가 계획과 최종 수행 범위는 다음과 같다. 7월의 30장면 문제 관측을 계획한 장기 기억 비교의 완료 실적으로 대체하지 않았다.

표 25. 평가 계획과 최종 수행 범위

평가 질문	최종 수행 결과	미수행 또는 평가 범위 밖
오류 탐지와 정상 표현 보존	490개 LLM 기준 판정의 검출 성능, 구매 거절과 MP 불변 사례	계획한 균형 도전 표본 및 독립 인간 판정, 최종 표시 전체의 오류율
장기 진행과 기억	15행동 단위 진행·복원, 6장면 고정 기억 문항 10쌍, 요약 전달 사례	계획한 20~30장면 장기 기억 검사와 동일 조건의 확장 비교
이미지 일관성	인물 표현을 앱에 연결	계획한 2인물·15표정의 독립 2인 평가; 본문 환각 통제 성능과 별도
저장과 재개	분리 로드와 재개 응답의 상태 일치	실제 기기 강제 종료, 서버 재시작, 네트워크 재연결
모델 부담과 비용	역할 분리와 토큰별 비용 집계	동일 조건의 모델·아키텍처 비교에 따른 비용·지연 효과

5. 결론 및 향후 연구 방향

5.1. 연구 결론

본 과제는 상태가 누적되는 LLM 서사 시스템에서 생성의 자유와 게임 결과의 일관성을 함께 다루는 환각 통제 아키텍처를 설계하고 구현하였다. Hallucination의 텍스트 RPG에 규칙 기반 실행, 4계층 기억과 관계 하이퍼그래프, 생성 후보의 검수, 상태 확정과 저장을 통합하고 Flutter 앱에서 플레이할 수 있도록 구성하였다. 핵심 기여는 개별 모델 응답의 정확성에만 의존하지 않고, 선택에서 실행·경험·후속 장면으로 이어지는 정보와 권한의 경계를 소프트웨어로 관리한 것이다.

자연어 선택과 실행의 연결에서는 정산이 필요한 대상과 효과를 명시하고, 서버가 확정된 사건을 후속 생성에 제공하였다. 파티 수락 사례에서 선택 문구, 후속 대화, 실제 2인 명단과 기억 추출이 같은 사건을 가리켰다. 사후 선정한 8세션의 120확정행동·128표시장면에서는 파티 명단·파티장·위치에 대한 기대 상태 비교 43건이 일치하였다. 이는 평가한 기능 사례에서 자연어 선택과 정산을 연결한 구현의 작동을 보여준다.

경험 처리에서는 최근 원문과 장기 요약의 역할을 나누고, 현재 인물과 연결된 공유 경험을 생성 입력에 공급하였다. 경험 요약이 후속 요청에 전달되는 실제 사례를 확인했으며, 별도 FULL/MO 10쌍 비교에서는 지연 회상 6/10 대 0/10, 새 사실 반영 7/10 대 0/10의 차이를 관측하였다. 해당 모델·문항과 LLM 기준 판정 아래에서 장기 기억 입력이 회상과 갱신에 기여할 수 있음을 확인한 결과이다. 관계 검색의 사례와 이 비교는 기억·관계 구조를 지속적인 생성에 활용하는 서로 다른 근거이다.

상태 보호에서는 후보 검수의 결과를 실제 적용과 복구에 연결하였다. 구매 정산이 없는 완료 후보를 거절하면서 기존 소지금과 소유물을 유지한 사례, 서술의 회복 표현과 무관하게 실제 MP가 유지된 사례를 확인하였다. 검수 원문과 실제 표시의 연결 및 복구 시 이전 장면의 유지도 확인하였다. 분리 로드 24회와 재개 응답 240필드도 일치하여 확정 상태를 저장하고 다시 구성하는 경로를 검증하였다. 이러한 결과는 생성 문장이 잘못되더라도 그 문장 자체에 게임 수치의 변경 권한을 주지 않는 설계의 의의를 보여준다.

평가 자료에서는 의미 검수의 미탐·오탐과, 잘못된 서술이 표시와 기억에 남는 사례도 관측하였다. 이는 상태 보호와 함께 최종 서술 및 기억 내용의 정확성을 별도로 평가하고 개선해야 함을 보여준다. 본 과제는 실제 플레이 가능한 시스템에서 상태 보호, 경험 활용, 서술 정확성을 분리하여 구현하고 평가함으로써, 생성형 게임의 일관성을 다룰 수 있는 구체적인 아키텍처와 실증 근거를 제시하였다.

5.2. 향후 연구 방향

후속 연구의 첫 번째 과제는 사용자에게 전달되는 최종 서술의 사실성을 높이는 것이다. 검출기의 정밀도와 재현율을 함께 개선하고, 독립적인 인간 판정으로 오류와 정상 표현의 구분을 확인할 필요가 있다. 원후보의 차단 여부에 더해 대체 후보와 최종 표시를 연결하여 실제 오류 노출, 정상 표현의 거절, 추가 생성에 따른 지연과 비용을 평가해야 한다.

두 번째 과제는 더 긴 플레이에서 경험의 출처와 현재성을 유지하는 것이다. 기억 계층과 입력 예산의 기여를 분리해 비교하고, 관계 검색으로 찾은 공동 경험이 재등장 장면과 선택에 어떻게 사용되는지 평가할 필요가 있다. 검색한 내용의 전달 여부와 그 내용의 정확성을 함께 확인하여, 오래된 정보나 잘못된 요약이 후속 장면의 전제가 되는 문제를 다루어야 한다.

세 번째 과제는 사용자 환경에서의 통합 품질 평가이다. 실제 기기의 강제 종료, 서버 재시작과 네트워크 재연결로 복구 검증을 넓히고, 사용자가 선택의 효과를 이해하는 정도와 읽기 편의, 기다림, 몰입을 확인할 필요가 있다. 상위 층과 장기 관계를 포함하는 평가는 초기 층에서 확인한 구조가 더 다양한 상태와 경험에서도 유지되는지를 검증하는 확장 방향이다.

6. 참고 문헌

- [1] Z. Ji et al., “Survey of Hallucination in Natural Language Generation,” *ACM Computing Surveys*, vol. 55, no. 12, article 248, 2023. doi:10.1145/3571730.
- [2] A. Zhu, L. J. Martin, A. Head, and C. Callison-Burch, “CALYPSO: LLMs as Dungeon Masters’ Assistants,” 2023. arXiv:2308.07540.
- [3] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative Agents: Interactive Simulacra of Human Behavior,” *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, 2023. doi:10.1145/3586183.3606763.
- [4] C. Packer et al., “MemGPT: Towards LLMs as Operating Systems,” 2023. arXiv:2310.08560.
- [5] P. Anokhin et al., “AriGraph: Learning Knowledge Graph World Models with Episodic Memory for LLM Agents,” 2025 revision. arXiv:2407.04363.
- [6] S. Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” *International Conference on Learning Representations*, 2023. arXiv:2210.03629.
- [7] P. Manakul, A. Liusie, and M. J. F. Gales, “SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models,” 2023. arXiv:2303.08896.
- [8] S. Dhuliawala et al., “Chain-of-Verification Reduces Hallucination in Large Language Models,” 2023. arXiv:2309.11495.
- [9] T. Rebedea, R. Dinu, M. Sreedhar, C. Parisien, and J. Cohen, “NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications with Programmable Rails,” 2023. arXiv:2310.10501.
- [10] M. T. Ribeiro, T. Wu, C. Guestrin, and S. Singh, “Beyond Accuracy: Behavioral Testing of NLP Models with CheckList,” *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020. arXiv:2005.04118.
- [11] S. Yao, N. Shinn, P. Razavi, and K. Narasimhan, “ τ -bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains,” 2024. arXiv:2406.12045.