

개요

문제 제시

LLM 환각 — 확인되지 않은 사실의 생성

AI는 입력에 없는 내용을 사실처럼 만들어낸다.

상태가 누적되는 시스템에서는 한 번의 잘못된 서술이 이후 모든 진행의 전제가 되어 되돌릴 수 없다.

실제 시뮬레이션에서 관측된 AI 환각 예시

- 체력이 가득한 상태에서 "탈진했다"고 서술
- 구매 기록 없이 "물약을 구매했다"고 서술
- 발생하지 않은 전투가 15장면 연속 전개

서술 오류가 확정 상태로 번지면 이후 진행 전체가 무너진다

WHY?

왜 텍스트형 RPG에서 측정하는가

체력·소지금·전투 결과에 시스템이 확정된 정답이 있기 때문에, 같은 조건을 반복 재현하고 잘못된 서술과 실제 상태 오염을 분리해 관찰할 수 있다. 게임은 결과물이 아니라 환각을 측정하기 위한 실험 환경이다.

해결 방안

계산·기억·검증을 나누어 모델의 부담을 줄이고, 환각을 통제

전투·자원 계산과 상태 확정은 시스템이 맡고, LLM은 장면·대화·선택만 생성한다. 부담을 모델 밖으로 나누면 경량 모델로도 규칙 안에서 서사가 이어진다.

생성 전	계층형 기억	그 장면에 필요한 과거 사실만 공급
생성 후	생성 검증	근거 없는 서술은 표시 전에 차단
상태 반영	책임 분리	체력·소지금·전투 결과는 코드가 확정
개발·평가	자동 평가	실패를 재현하고 반복 측정

환각의 발생·탐지·상태 오염을 분리해 측정한다

핵심 설계와 구조

결정론적 연산-서술 분리

플레이어의 선택 · 게임 규칙

코드가 확정하는 게임 결과

전투 시뮬레이션 → 승패·피해·자원 소모

아이템·장비 → 소모·획득·장착

이동·성장 → 위치·경험치·레벨

확정 상태와 정산 기록을 서술·검증에 공급

기억·관계·세계에서 필요한 맥락을 선별

<4계층 기억>

감각 현재 장면
작업 최근 맥락
일화 사건 요약
의미 축적 지식


보존·요약·계층별 입력 예산

관계 하이퍼그래프

인물 경험 장소
집단

관계로 연결된 경험을 검색


AI 플레이어·세계



인물·집단과 세계 사건의 변화를 장면 맥락에 반영

다계층 검증과 상태 보호

검증 근거: 현재 상태·정산 기록



검수 거절 시 반영 중단
후보를 표시하지 않고 미확정 변경을 복원

앱·서버·저장 연동
Flutter와 FastAPI의 REST·SSE 통신으로
확정 결과를 전달하고 서버 상태로 재개한다.

구현 및 평가


확정한 경험을 후속 장면에 재사용

선택이 사건과 인물 반응으로 이어지는 플레이

엘비라의 파티 제안을 수락하고, 인물의 반응과 실제 파티 구성을 확인했다.


실제 플레이 화면 발췌

플레이어의 선택



파티 제안 수락

인물들의 반응




파티 결정과 감사 인사

게임 상태 반영



파티 결정

서술 검증의 탐지 성능

생성 문장 490개에 대한 LLM 판정을 기준으로
검수 결과를 대조했다. 위반 탐지와 정상 문장 오탐을 구분한다.

걸러낸 서술은 보여주지도, 저장하지도 않는다

ex) 구매 정산 없이 "구매 완료"를 서술한 후보를 거절했다.
화면에 표시하지 않고 골드 100G와 기존 장비를 유지했다.

실제 실행 사례 · Gemini 3.8 Flash / LOW

회복 서술에도 MP 증가 없음

필드 대기 장면의 입력·서술·실제 상태를 대조했다.

LLM에 제공한 규칙·현재 상태
필드에서는 시간 경과로 MP가 회복되지 않음
현재 위치: 신록의 평야(필드) · MP 11/106

LLM 서술
"비거점 필드인 탓에
자연 회복으로 차오르는 마력의
속도는 더디기 짝이 없었다."

실제 MP

11 → 11
대기 전 대기 후

생성 문장의 회복 묘사가 실제 MP 증가로 이어지지 않았다.

실제 플레이 오류 사례 1건 · Gemini 3.8 Flash / LOW · 입력·행동 기록 대조